



2024 年度 修士論文

津波避難誘導のマルチエージェント 強化学習ドローンによるアプローチ の検討

23VR008N 高林秀

指導教員 三宅陽一郎

立教大学大学院
人工知能科学研究科 人工知能科学専攻

概要

本研究は、津波避難誘導における津波避難ビルへの避難完了率の最大化を目的として、マルチエージェント強化学習を活用した自律飛行型ドローンモデルを提案する。観光地や都市部における避難者の多様性を考慮し、複数ドローンの協調行動により避難者を適切な避難所へ誘導する。特に、MA-POCA アルゴリズムを用いてエージェント間の協調性を強化し、ゲーム AI 技術や 3D 都市モデル技術を活用して現実の都市環境を再現したシミュレーション実験を実施した。実験は都市内の避難者を探索し誘導する群衆を形成する探索タスクと、群衆を避難所へ誘導する誘導タスクに分けてを行い、比較実験によりその有効性を検証した。結果、今回作成したマルチエージェントモデルは、ルールベースで行動する場合より良い結果を得ることは出来なかったが、避難所誘導タスクにおいては、ルールベースで行動するドローンエージェントの誘導がない場合と比較して、避難完了率が向上することが確認された。

目次

第 1 章	はじめに	2
1.1	要旨	2
1.2	本稿の構成	2
第 2 章	研究背景	3
2.1	津波避難誘導における課題	3
2.1.1	訪日観光客数の増加と観光地における避難誘導の課題	3
2.1.2	津波避難タワー・津波避難ビル	4
2.1.3	二次被害の発生	6
2.2	既存のドローンの災害対応における活用事例と航空法改正	7
2.2.1	ドローンによる避難誘導の先行研究と自治体の実証実験の事例	7
2.3	強化学習	8
2.3.1	マルチエージェント強化学習の基本概念	9
2.3.2	MA-POCA (MultiAgent POnthumous Credit Assignment)	11
2.4	ナビゲーションメッシュ	13
2.4.1	a^* アルゴリズム	13
2.5	強化学習エージェントのデジタルツインへの応用	14
2.5.1	sim2real (Simulation to Reality)	15
第 3 章	提案手法と実験概要	17
3.1	提案手法の概要	17
3.2	既存研究との新規性	18
3.3	実験概要	19
3.4	シミュレーション前提条件	19
3.4.1	都市モデルの選定と避難所の配置条件	19
3.4.2	避難者の前提条件	21
3.4.3	避難所収容人数の前提条件	21
3.4.4	エージェントの前提条件	21
3.5	避難者探索タスク実験方法	22

3.6	避難所誘導タスク実験方法	23
第4章	実験結果と考察	26
4.1	避難者探索タスク実験	26
4.1.1	モデル学習結果	26
4.1.2	実験結果	28
4.1.3	結果の考察	29
4.2	避難所誘導タスクの結果	30
4.2.1	モデル学習結果	30
4.2.2	実験結果	32
4.2.3	結果の考察	35
第5章	結論	37
5.1	実験のまとめ	37
5.2	ドローンによる津波避難誘導の実現可能性	38
5.3	今後の展望	38
参考文献		41
.1	シミュレーションソース格納先	43
.2	特別研究レポート格納先	43
.3	探索タスクマルチエージェントモデルの学習結果	43
.3.1	横須賀市の場合	43
.3.2	沼津市の場合	44
.4	誘導タスクマルチエージェントモデルの学習結果	45
.4.1	横須賀市の場合	45
.4.2	沼津市の場合	46
.5	探索タスクにおける発見率の推移	48
.5.1	横須賀市の場合	48
.5.2	沼津市の場合	49
.6	誘導タスクにおける避難完了率の推移	50
.6.1	横須賀市の場合	50
.6.2	沼津市の場合	51

第1章

はじめに

本章では、本論文の要旨および構成について述べる。

1.1 要旨

首都直下型地震や南海トラフ地震をはじめとする、大地震の30年以内の発生確率が70%～80%と非常に高くなっていることに加え、近年の豪雨など、将来の大規模災害のリスクが著しく高まっている現状がある。このような背景の下、本研究では、津波避難誘導における避難完了率最適化と誘導人員のリスク軽減を目的として、マルチエージェント強化学習を活用した自律飛行型ドローンによる津波避難誘導モデルを提案する。複数のドローンが協調して避難者を最適な避難所に誘導する方策を強化学習により求め、ゲームAIと3D都市モデルを用いた現実に近いシミュレーション環境による効果検証を実施した。本提案手法により、津波避難誘導の課題解決に寄与することを目指す。

1.2 本稿の構成

まず、第2章において本稿の内容を理解するのに必要な事前知識、研究背景について述べる。具体的には、以下の項目について説明する。

- 強化学習についての基本説明
- マルチエージェントアルゴリズム MA-POCA (MultiAgent POsthumous Credit Assignment) について
- 本研究の社会的背景・課題について

次の第3章においては、提案手法の説明と本研究の研究方法についての説明を行う。第4章では、マルチエージェント強化学習エージェントによる、津波避難誘導のシミュレーション実験の結果と考察を行う。第5章では、実験結果をまとめ、マルチエージェントドローンによる津波避難誘導の実現可能性について論ずる。また、今後の研究の展望を述べる。

第2章

研究背景

本研究を理解する上で必要な概念である、強化学習とそのアルゴリズムである MA-POCA の理論や、関連する研究について述べる。また、本研究を行うことになった社会的背景についても述べる。

2.1 津波避難誘導における課題

本章では、我が国での津波避難誘導における課題について取り上げ、後述する提案手法の研究背景の理解を補助するものとする。

災害大国である我が国において、地震発生後の津波避難誘導オペレーションは非常に重要な課題である。また近年、津波以外にも異常気象等による気象災害の激甚化もあり、避難誘導の遂行にあたって、益々その危険性も増していると推察される。

2.1.1 訪日観光客数の増加と観光地における避難誘導の課題

近年の大幅な観光客増加と、観光地における避難誘導の課題、その関連性について述べる。

我が国の観光客数増加 我が国では、2007年に観光立国推進基本法^{*1}が施行され、国として観光客数の増加が進められてきた。観光庁の調査によれば、我が国における訪日外国人観光客数は増加の一途を辿っている。図2.1は観光庁が公開している、2003年から2023年までの訪日外国人観光客数の推移を示したグラフである。

^{*1} 議員立法により平成18年12月13日に成立し、平成19年1月1日から施行されている。本法律において、観光は21世紀における日本の重要な政策の柱として初めて明確に位置づけられた。

訪日外国人旅行者数・出国日本人数の推移

国土交通省
観光庁

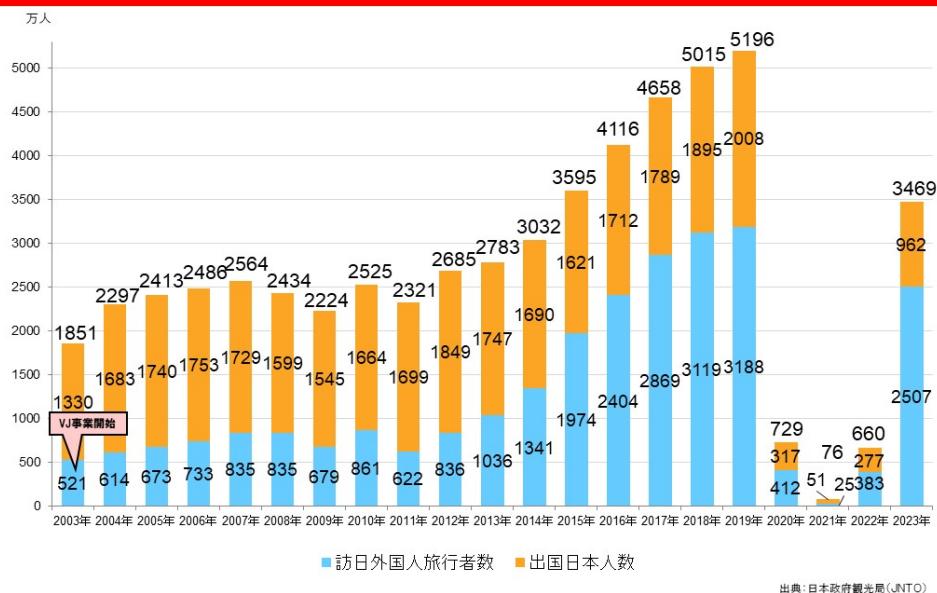


図2.1: 2003年～2023年の訪日外国人旅行者数の推移

図2.1を読み解くと,2003年から2019年にかけて,訪日外国人観光客数は倍以上に増加していることがうかがえる.2020年から2022年にかけては,著しく観光客数が減少しているが,これは新型コロナウイルスの世界的流行による影響であると考えられる.

また,2023年は新型コロナウイルスによる行動自粛が解除されたことを受け,観光客数は2015年と同等水準まで回復しており,今後も増加するものと推察される.

このような観光客数の急激な増加は,観光地の災害時の避難誘導タスクにおいて,以下のような問題を生じさせ適切な避難誘導を行えない可能性がある.

- ・観光客の土地勘がないため,的確な避難誘導が必要
- ・観光客数は時間や季節によって変動するため,特定の避難所に多数の避難者が向かい,収容不足となる可能性がある.
- ・避難誘導に従わず周囲の人の動きに追従し,混乱を招く恐れがある.

このような,観光客の避難に関する問題は,多くの関連研究でも指摘されている.

2.1.2 津波避難タワー・津波避難ビル

我が国には,津波避難タワーや津波避難ビル^{*2}が建設されており,津波からの公的な避難先の1つとして提供されている.

*2 津波浸水が想定される地域において,地震発生時に住民が一時的,または緊急に避難・退避するための人工施設を言う.内閣府が2005年に策定した「津波避難ビル等に係るガイドライン」に沿って進められ,2011年の東日本大震災^{*3}の発生を受け,「津波防災地域づくりに関する法律」によって津波防災対策が制度化された.



(a) 静岡県磐田市の津波避難タワー



(b) 宮城県石巻市の津波避難ビル

図2.2: 実際の津波避難ビルと津波避難タワー

このような施設の建設にあたっては、避難経路や避難時間などの基準が国から示されており、自治体により適切な位置に建設が進められている。特に、観光地では景観等の問題から、十分な高さの堤防や防波堤を用意することが難しいといった問題もあり、津波避難対策を強化する施策としてこのような津波避難施設の設置が自治体を主導に行われている。このような施設は、津波から命を守る手段として非常に重要であるが、避難者の行動、配分によっては収容定員を超過し、適切な避難が行えない可能性があることが示されている [1]。

しかし、その母数が足りず想定される避難者の数をカバーしきれない等の指摘や、被害予測の改訂等で必要な高さ等の基準を満たせていない等の問題も存在する [2]。加えて、ほとんどの観光客は土地勘がないとともに、防災意識もあまり高いとは言えない結果がアンケート調査で判明している。[3]。

このような状況下では、近隣の高台へ避難することが求められるが、土地勘のない観光客や外国人観光客に対してこれを求めるのはかなり難しく、既往研究の多くで指摘されている問題である。

また、観光地特有の問題として一部の避難所に避難者が集中し、避難完了時間が遅くなるというシミュレーション結果が示されており、適切に他の避難所（ないしは避難ビル）に避難者を誘導することの必要性が指摘されている [4]。

以上の背景から、今後発生しうる、南海トラフ地震などの巨大地震とそれにより発生する津波からの避難に関して、その対策は進められてきてはいるものの、地元住民だけでなく観光客も含めた避難に関しては多くの課題を残している現状がある。また、避難する人だけでなく、避難者を適切な場所へ誘導する人員の安全確保にも課題が残されている。

2.1.3 二次被害の発生

津波避難誘導（あるいは、他の災害における避難誘導）においては、発災直後から二次被害にあう危険性が高い地域で活動しなければならないため、現場で誘導を行う警察や消防員等の安全確保が問題になっている。

風水害時における人的被害の特徴 図2.3は、我が国で発生した1969年から2018年までの災害を対象に、消防団員が殉職した事例を消防白書や新聞記事、既往研究などから把握し、殉職時の状況を分析した結果が、山田らの研究[5]によって報告されており、これを引用して紹介する。

図-3より、津波は、出動途上、水防作業中、避難中、避難誘導中、人命救助中に殉職者を出したことがわかった。なかでも避難誘導中と避難中を合わせると全体で約80%を占めており、避難に関係する時に殉職者が出ていている。

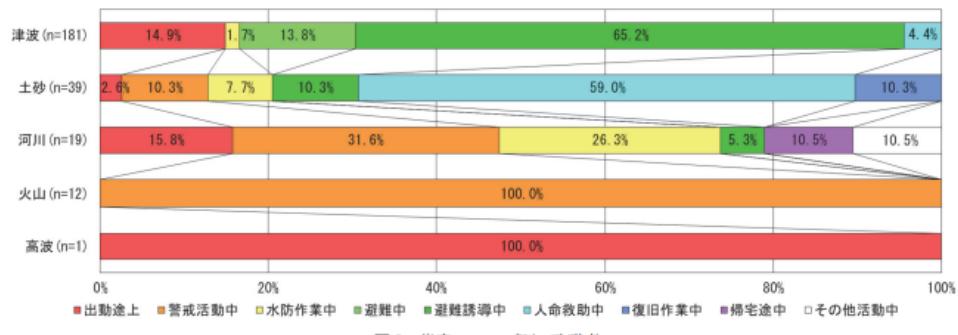


図2.3: 消防団員の災害フェーズ別殉職者の割合

以上より、津波災害時の消防団員における2次被害に関しては、避難誘導中が最も多い結果であることが示されている。上記は消防団員に限定した統計であるが、同じく避難誘導を行うすべての人員においても同様の傾向があると推察される。

また、東日本大震災のケースにおいても、避難誘導にあたった警察職員や自治体職員の多数が地域住民の避難誘導中に津波に巻き込まれ殉職された事例が報告されており[6][7]、このような二次被害の防止は避難誘導において重要な意味を持つ。

2.2 既存のドローンの災害対応における活用事例と航空法改正

加えて、我が国では、2022年に航空法が改正され、これまで規制されていたドローンの有人地帯目視外飛行（レベル4飛行^{*4}）が解禁された。これにより、これまでドローンの活用が規制されていた防災分野での利活用や研究が大きく進んだ背景がある。

	操縦方法	視界	飛行可能場所
レベル1	操縦飛行	目視内	無人/有人地帯
レベル2	自律飛行	目視内	無人/有人地帯
レベル3	自律飛行	目視外（補助者無し）	無人地帯
レベル4	自律飛行	目視外（補助者無し）	有人地帯

表2.1: ドローンの飛行レベル別概要

近年我が国では、少子高齢化に伴う労働人口の減少の問題もあり、災害対応人材の不足が懸念されている背景がある。そのような人手不足に対応するため、ドローン等による災害対応の機械化・省人化が進められ始めている。総務省・消防庁が公開しているデータ[8]によると、全国の消防本部におけるドローンの活用率は年々上昇しており、2017年には9.6%だったものが、2021年には52.9%と全国半数以上の消防本部でドローンの利活用が進められたことが報告されている。

2.2.1 ドローンによる避難誘導の先行研究と自治体の実証実験の事例

ドローンを初めとする UAV の津波避難誘導に置ける活用方法を検討した既往研究が存在する。杉安らの研究では、津波避難時の迅速な避難行動を促進するために、UAV（無人航空機）の活用可能性を示し、避難誘導を視覚的に行うことの目的とし、福島県いわき市を対象に実証実験を行っている[9]。

また、本研究と関連する先行研究事例として、鈴木らが行った協調ドローンを用いた避難誘導支援システムの研究がある[10]。この研究では、ドローンを活用して、安全な避難経路を生成し、被災者を誘導するシステムを提案している。被災者は AR マーカーを身に着け、ドローンがこれを識別することで位置情報を取得し、後述する a^* アルゴリズムにより避難経路を探索し、計算した軌道情報を沿って対象者を誘導するものである。この研究では実機による誘導試験も行っており、ドローンによる避難誘導の実現可能性を示した。もう一つの先行研究事例として、複数のドローンが連携して避難誘導を行うことを検証した高橋らの研究が存在する[11]。この研究では、自然災害時に UAV（無人航空機）を活用して避難誘導を行う

^{*4} 無人機の運用・操縦方法をレベル別に定めたもの。レベル4では操縦者が直接目視で機体を見ていても有人地帯でドローンを飛ばすことが可能になった。

支援システムの設計と試作について述べている。このシステムは複数の UAV が連携して避難者を誘導する仕組みを構築しており、沿岸部地域を対象にした実証実験まで行っている。UAV エージェントによる避難誘導プラン生成と経路選択、複数の UAV の協調による避難誘導機能の実現可能性が示された。

また、改正航空法の施行後、沿岸部の自治体を中心に、津波避難誘導を行うドローンの研究や実証実験が進められている。宮城県仙台市では、東日本大震災の際に津波避難誘導を行っていた自治体職員が津波に巻き込まれ犠牲になった事例を受け、津波避難を呼びかける手段として津波避難広報ドローンの研究が行われている [12]。この実証実験は、「自動運航のドローンにより津波避難広報を行うこと」及び「専用の LTE 通信網でドローンの制御等を行うこと」の 2 点において世界初の事例で、J アラート⁵による津波情報を受信した後、飛行経路上の気象条件を確認し自律的にドローンの飛行可否を判断した後、事前に定められた飛行ルート上を飛行しながら津波避難のアナウンスを行うというものである。また、ドローンの管制システムには専用の LTE 通信網を利用しておおり、令和 4 年 10 月に整備を完了し本格運用に入っている。

以上の様に、ドローンを用いた避難誘導システムの基礎研究や、自治体による避難誘導案内ドローンの整備など、災害時の避難誘導においてドローンの活用が検討、実装が進められている。

ただし、これらの研究事例においては、後述する提案手法で示す、本研究が行うような要避難者の位置分布に基づいた各ドローンの配置や移動、避難先の収容人数を考慮した避難誘導の最適化は行われていない。これらの点を後述する提案手法の章にて、本研究が示す新規性として具体的に述べる。

2.3 強化学習

強化学習とは、エージェント⁶と環境⁷との相互作用を通じ、得られる報酬⁸を最大化するエージェントの方策⁹を学習する機械学習アルゴリズムの種類である。

⁵ 全国瞬時警報システム（J アラート）とは、弾道ミサイル情報、緊急地震速報、大津波警報など、対処に時間的余裕のない事態に関する情報を携帯電話等に配信される緊急速報システム

⁶ モデルを訓練するための主体。環境に対して行動を出力する。

⁷ エージェントがいる世界、モデルの訓練を行うための様々な機能や状態を提供する。

⁸ エージェントの行動の良し悪しを判断する評価値。行動に対する環境からの評価

⁹ ポリシーとも呼ばれる。環境の状態に基づいて、次の行動を決定するためのルール

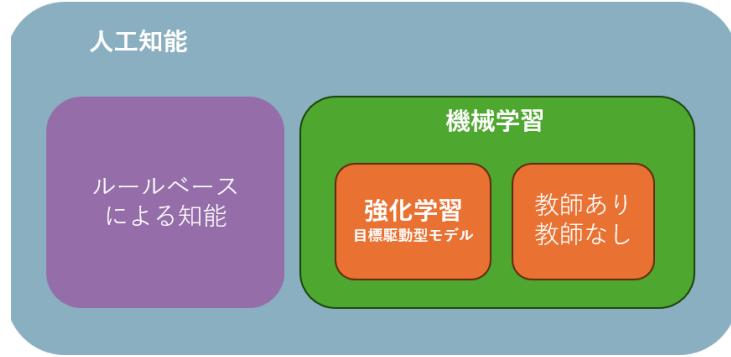


図2.4: 強化学習の枠組み概念図

教師あり学習・教師なし学習のデータ駆動型機械学習モデルと異なり, 事前に訓練データを作成する必要はなく, 訓練に必要なデータはエージェントが環境から得るものである. 強化学習は与えられた環境の中で, 最適な戦略行動(方策)を分析することが目的となる. このような特性から, 強化学習は目的駆動型モデルや行動駆動型モデルと呼ばれることもある. エージェントの一連の流れである「観測」, 「行動出力」, 「報酬獲得」のサイクルを決定と呼ぶ.

2.3.1 マルチエージェント強化学習の基本概念

マルチエージェント強化学習 (Multi-Agent Reinforcement Learning, MARL) では, 複数のエージェントが環境と相互作用し, それぞれが自身の行動方策を学習しながら, 協調または競争を行う. 以下にその基本的な数式を示す.

環境の定義

環境は, 部分観測可能マルコフ決定過程 (Decentralized-POMDP) として定義される:

$$\mathcal{M} = \langle N, S, \{O_i\}_{i=1}^N, \{A_i\}_{i=1}^N, P, r, \gamma \rangle$$

ここで:

- N : エージェントの数
- S : 環境の状態空間
- O_i : エージェント i の観測空間
- A_i : エージェント i の行動空間
- $P(s'|s, \mathbf{a})$: 状態 s と行動の組み合わせ $\mathbf{a} = (a_1, a_2, \dots, a_N)$ から次の状態 s' への遷移確率
- $r(s, \mathbf{a})$: 共有報酬関数
- γ : 割引率

エージェントの行動方策

各エージェント i は、観測 O_i に基づき行動を選択する方策 $\pi_i(a_i|o_i)$ を学習する。エージェント全体の方策は次のように表される：

$$\pi(\mathbf{a}|\mathbf{o}) = \prod_{i=1}^N \pi_i(a_i|o_i)$$

状態価値関数と行動価値関数

- 状態価値関数 $V^\pi(s)$ は、状態 s から始まり方策 π に従ったときの期待累積報酬である：

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, \mathbf{a}_t) \mid s_0 = s \right]$$

- 行動価値関数 $Q^\pi(s, \mathbf{a})$ は、状態 s で行動 \mathbf{a} を取った場合の期待累積報酬である：

$$Q^\pi(s, \mathbf{a}) = r(s, \mathbf{a}) + \mathbb{E}_\pi \left[\sum_{t=1}^{\infty} \gamma^t r(s_t, \mathbf{a}_t) \right]$$

集中化された Critic

MARL では、集中化された Critic を用いて全エージェントの観測 \mathbf{o} と行動 \mathbf{a} を基に価値関数を近似する：

$$Q^\pi(s, \mathbf{a}) = f_\phi(s, \mathbf{a})$$

ここで f_ϕ はパラメータ ϕ を持つ関数近似器（通常はニューラルネットワーク）である。

Advantage 関数

アクター・クリティックアルゴリズムでは、Advantage 関数を用いて方策の更新を行う：

$$A^\pi(s, \mathbf{a}) = Q^\pi(s, \mathbf{a}) - V^\pi(s)$$

方策の更新

エージェントの方策は、Advantage 関数を最大化するように勾配上昇法で更新される：

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) A^\pi(s, a)]$$

協調と競争

協調タスクでは、全エージェントがグループ報酬 $r(s, a)$ を最大化する。一方、競争タスクでは、各エージェントが自分の報酬を最大化する。

2.3.2 MA-POCA (MultiAgent POnthumous Credit Assignment)

環境内のエージェントの個体数の増減に対応し、エージェント間の協調行動を重んじるようなタスクを学習するのに適しているアルゴリズムが MA-POCA (MultiAgent POnthumous Credit Assignment) [13] である。

MA-POCA は既存のマルチエージェントアルゴリズムと比較して、以下の特徴を持つ。

- 環境内のエージェント数の増減に対応した学習が可能
- エピソード内でエージェントが生成・消滅するタスクや、標準的な協調タスクにおいて、既存手法を大幅に上回る性能を示した

例えば、実世界で動くようなドローンをエージェントとして、その群衆飛行を考えた時、あるバッテリーが切れたり、故障したりすることが考えられ、エージェントが他のエージェントよりも先に行動不能（早期終了）になる場合が考えられる。既存のマルチエージェントアルゴリズムは、エージェントがエピソード^{*10} 終了前に消滅した場合、そのエージェントの行動出力に関係なく状態を固定することでこれを再現する。これを吸収状態と言い、このようにすることで Critic への入力数を固定したまま学習を行うことが出来るが、同時に無駄な情報を入力しているとも捉えることができ、環境内のエージェント数が多いほどこの問題は顕著に出現することが指摘されている。

早期終了になったエージェントは、与えられたグループ報酬を経験することができない為、自身の行動のグループにおける価値を計算することができない。MA-POCA は、この問題を解消するために提案されたアルゴリズムで、エージェントが早期終了しても価値を伝搬させるアルゴリズムとなっている。

MA-POCA の性能評価 MA-POCA は既存の MARL 手法よりも多くの場合で性能が向上することが報告されている [13]。図2.5のような 4 つの実験環境において、マルチエージェント強化学習手法 COMA^{*11}、そして、シングルエージェント強化学習手法 PPO^{*12} と

^{*10} エージェントが環境と相互作用してタスクを完了するまでの一連のステップのこと。例えば、迷路のスタート地点からゴール地点までの移動がこれに該当する。一方、「ステップ」とは、そのエピソード内でエージェントが 1 回行動を選択し、環境から報酬と次の状態を受け取る単位時間のことである。

^{*11} COMA (Counterfactual Multi-Agent Policy Gradients) は、マルチエージェント強化学習 (MARL) における協調型環境向けの手法で、特に中央批評家 (centralized critic) を活用してクレジット割り当てを改善するアルゴリズム

^{*12} PPO (Proximal Policy Optimization) は、シングルエージェント強化学習において安定した方策 (Policy) 更新を実現するためのアクター-クリティック型手法

MA-POCA の性能を比較した結果が示されている。



図2.5: MA-POCA の性能評価を実施した環境

- (a) **Collaborative Push Block** エージェント（青, 黄, 紫）は白いブロックを緑の領域まで押す。大きなブロックはより多くのエージェントが押す必要がある。
- (b) **Simple Spread** エージェント（紫）は互いにぶつからることなく、ターゲット（黒）をカバーするように移動しなければならない。
- (c) **Baton Pass** 青いエージェントが緑色の food をつかみ、緑色のボタンを押すと別のエージェントが生まれ、次の food をつかむことができるようになるので、それを繰り返す。
- (d) **Dungeon Escape** 青いエージェントは緑のドラゴンを倒し、そのうちの1人を犠牲にしてカギを出さなければならない。チームメイトは鍵を拾って、ピンクのドラゴンを避けながら、ドアまでたどり着くタスク。

以下の引用図2.6は、上記4環境における、累積報酬の推移を示している。このように、MA-POCAは既存のMARL手法よりも多くの場合で性能が向上することが報告されている。

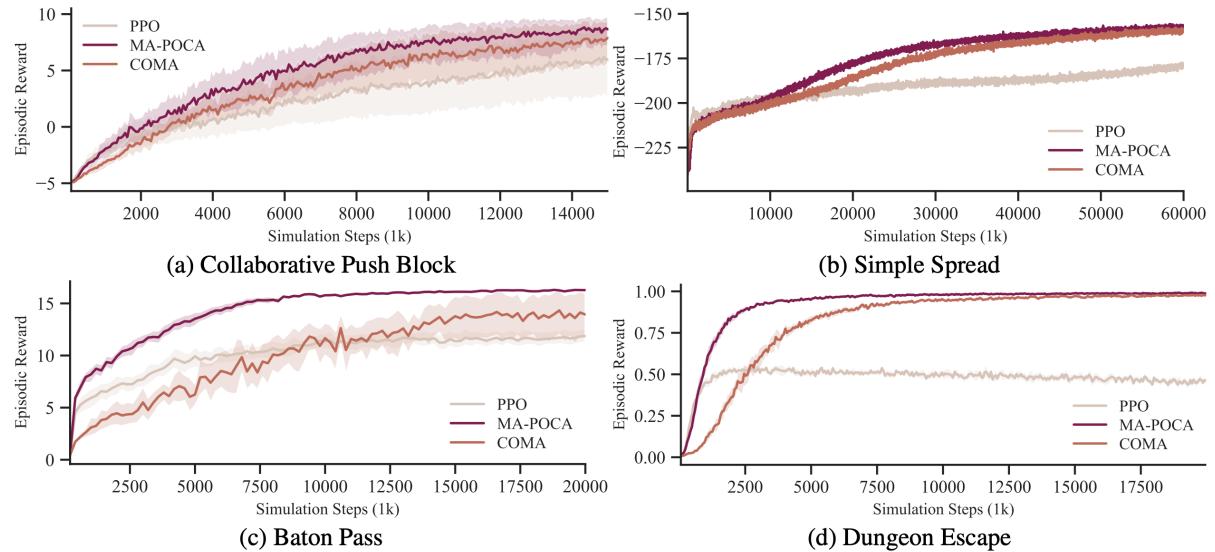


図2.6: 各環境での MA-POCA の性能評価結果

2.4 ナビゲーションメッシュ

デジタルゲームにおける人工知能 [14] には大きく 3 つの種類がある.

- キャラクター AI : ゲームやシミュレーション内で使用する NPC の頭脳
- メタ AI : ゲームやシミュレーション全体を監督し, 難易度等を調整する
- ナビゲーション AI : キャラクターの移動経路検索や障害物等の管理を行う

本研究では, エージェントの経路探索に上記のナビゲーション AI に区分される, ナビゲーションメッシュと呼ばれる機能を利用する. ナビゲーションメッシュは, ノード^{*13}の連結(グラフ)によって移動可能領域を覆うことで, キャラクターから移動可能範囲, 経路を認識させるためのゲーム AI 技術である.

都市モデル上でエージェントを動かす場合, あらゆる経路や移動手段が考えられ, エージェントが移動可能な道路や領域, 障害物として認識した上で行動するにはモデル訓練時の経験においてそれらを学習する必要がある. 本研究の目標は, エージェントが避難者を, 誘導人數や収容人數等を考慮し適切な避難所へ誘導することが目標なため, ナビゲーションメッシュを使用し事前にエージェントが移動可能な範囲を定めるものとする.

2.4.1 a* アルゴリズム

キャラクターの移動経路を探索するナビゲーション機能のアルゴリズムとしては a* アルゴリズムが広く利用されている. a* アルゴリズムは, 最短経路を探索するためのグラフ探索アルゴリズムで, 経路をノードとして表現しグラフ探索を行う.

スタートノードからゴールノードまでの最短経路を探索する際に, 次の評価関数 $f(n)$ を用いる:

$$f(n) = g(n) + h(n)$$

ここで:

- $f(n)$: ノード n の総評価値. スタートからゴールまでの推定コスト.
- $g(n)$: スタートノードから現在のノード n までの実際のコスト.
- $h(n)$: 現在のノード n からゴールノードまでの推定コスト (ヒューリスティック関数).

^{*13} このノードをウェイポイントデータと呼び, ダイクストラ法等のグラフ探索アルゴリズムを用いて最短経路を検索することが可能になる

アルゴリズムの手順

A* アルゴリズムは以下の手順で進行する：

1. スタートノードをオープンリストに追加し, 初期化する.
2. オープンリストから $f(n)$ が最小のノードを選択する.
3. 選択したノードがゴールノードであれば, 経路探索を終了する.
4. そのノードの隣接ノードを評価し, 以下を実行する：
 - 新しいノードであれば, $f(n) = g(n) + h(n)$ を計算し, オープンリストに追加する.
 - 既に評価済みのノードであれば, より低いコストが見つかった場合に更新する.
5. 評価済みノードをクローズリストに移動し, 2 に戻る.

ヒューリスティック関数

ヒューリスティック関数 $h(n)$ は, A* アルゴリズムの効率と正確性を左右する重要な要素である. 一般的な選択肢として以下がある：

- マンハッタン距離: 格子状のグラフで利用される.
- ユークリッド距離: 2D または 3D 空間での最短直線距離を近似.

$h(n)$ が許容可能 (ゴールまでの実際のコストを過小評価しない) である場合, A* アルゴリズムは最適解を保証する.

応用例

A* アルゴリズムは, 以下のような応用分野で利用される：

- ゲーム AI: キャラクターの経路探索.
- ロボティクス: 障害物を回避する経路計画.
- 地図アプリケーション: 最短経路の検索.

2.5 強化学習エージェントのデジタルツインへの応用

デジタルツインとは, 現実空間に存在する建物や人流などの情報をリアルタイムで観測し, ネットワーク技術等を使用して仮想空間上に再現する技術のことである. 現実世界と対になる「双子」をデジタル空間上に構築し, モニタリングやシミュレーションを行うことで, 社会やビジネスプロセスを進化させることができ, 近年注目されている技術分野である.

CRDS^{*14}の調査によると, デジタルツイン関連の研究は, 工学分野や計算科学分野を中心として, 2016年から2021年の過去5年間の研究論文数で約30倍に急増しており, 米国, ドイツ, 英国, 中国などでの研究開発が活発であり, 各国で大学, 公的研究機関, 民間企業が連携した研究プロジェクトが推進されていることが報告されている[15].

デジタルツインと強化学習を組み合わせることで, 現実空間で動作するロボットを仮想空間上で強化学習エージェントとして訓練をすることが可能になる. 具体的な事例としては, Unity^{*15}を活用してロボットのデジタルツインを作成し, 強化学習によるトレーニングを行うことで, 仮想環境内の動作学習と実世界での性能向上を計るという研究がある[16]. また, 我が国ではトヨタ自動車株式会社^{*16}とSCSK株式会社^{*17}工場の製造ラインをデジタルツインで再現し, 強化学習を活用してロボットの動作や生産プロセスの最適化を目指す取り組みがある[17].

2.5.1 sim2real (Simulation to Reality)

sim2realとは, デジタル空間内のシミュレーションで学習したモデルを実世界でモデル適用, 並びにタスクに適用する技術のことである. 現実空間でエージェントの訓練環境を構築するよりも, デジタル空間でのシミュレーションを用いて訓練を行う方が, 手軽に様々な環境条件を設定・試すことができ, 低コストでモデルの実装を行うことができる.

一般に, ロボット分野において, シミュレーション上の訓練環境では, 状態やその他要因により現実環境を完全に再現することは難しく, モデルの訓練環境と実環境(運用環境)とでギャップが生じる. このギャップが大きいと, エージェントが意図しない動きを行う可能性が高まり, 安全上のリスクを伴う. また, モデル訓練時にエージェントが行う試行錯誤による事故や故障のリスクを軽減できる点も, sim2real技術の利点である.

sim2real技術を用いてドローンの飛行制御訓練モデルを作成し, 現実空間での実機ドローン制御を行った研究がRana Azzamらにより行われた. この研究では, 深層強化学習(Deep Reinforcement Learning, DRL)を用いて, 動的環境における自律的かつゴール指向型のナビゲーションシステムを開発した. このシステムは, シミュレーション環境でエージェントをトレーニングし, 高精度なUAVコントローラーモデルを使用することで, 追加のsim2real転送技術なしで現実世界へ適用されている. また, 静的および動的障害物を回避しながら, 安全かつ効率的にUAVをゴール地点まで誘導することを可能にしている. さらに, 現実世界でのテストにおいて90%の成功率を達成したことが報告されている[18].

この研究は, 消防や救助, 監視, 物流などのシナリオにおいて, 高度な障害物回避機能を備えたリアルタイムのナビゲーションシステムとしての応用が期待されている. また, 単一

*14 国立研究開発法人科学技術振興機構研究開発戦略センター

*15 ユニティ・テクノロジーズ社が開発・提供するゲームエンジン. ゲーム開発の分野で世界シェアナンバー1を誇り,多くのRPGや位置情報ゲーム, VRコンテンツなどが制作可能.

*16 愛知県豊田市に本社を置く日本最大手の自動車メーカー.

*17 住友商事, 住友グループのシステムインテグレータ企業

の UAV 制御にとどまらず, 将来的には複数の UAV の協調制御への拡張も視野に入れている [18].

デジタルツインと強化学習の融合は, システム設計, 運用, 制御のすべてにおいて革新的な可能性を提供する. この組み合わせは, 安全性の向上, 効率性の最大化, コスト削減を実現し, 実世界の複雑な課題に対するソリューションを提供する手段として, 今後ますます重要性を増していくだろう. 製造業, 建築設備, ロボット工学, モビリティ制御など, 広範な分野での応用が期待される中, これらの技術が社会全体にもたらす恩恵は計り知れない.

第3章

提案手法と実験概要

本章では、本研究が最終的に目指す津波避難誘導問題への解決策として、マルチエージェント強化学習と自律飛行型ドローンを組み合わせた提案手法について述べる。また、提案手法が既存研究と異なる点や新規性についても論じる。

3.1 提案手法の概要

本研究では、観光地や都市部といった地元住民以外にも多数の人々が屋外に存在する状況を想定している。これには、日常的に避難訓練を受けていない観光客や土地勘のない訪問者も含まれる。このような状況や、前章で述べた避難誘導における課題を背景に、地震発生後の津波避難という非常に緊急性の高い場面を想定し、避難誘導を行うための手法を検討する。従来、自治体職員や警察・消防隊員といった人間が担ってきた避難誘導を、自律飛行型ドローンが代替するシステムを構築することを目標とする。

具体的には、マルチエージェント強化学習を活用し、複数のドローンエージェントが協調して行動する能力を学習させることで、刻々と変化する被災地域の状況を動的に認識し、群衆の避難完了率を最大化することを目指す。また、避難者の位置、避難経路上の障害物、各ドローンの位置などをリアルタイムに反映するデジタルツイン環境を構築し、その環境内で学習済みのエージェントがシミュレーションを通じて最適な誘導方法を実行できるようにする。

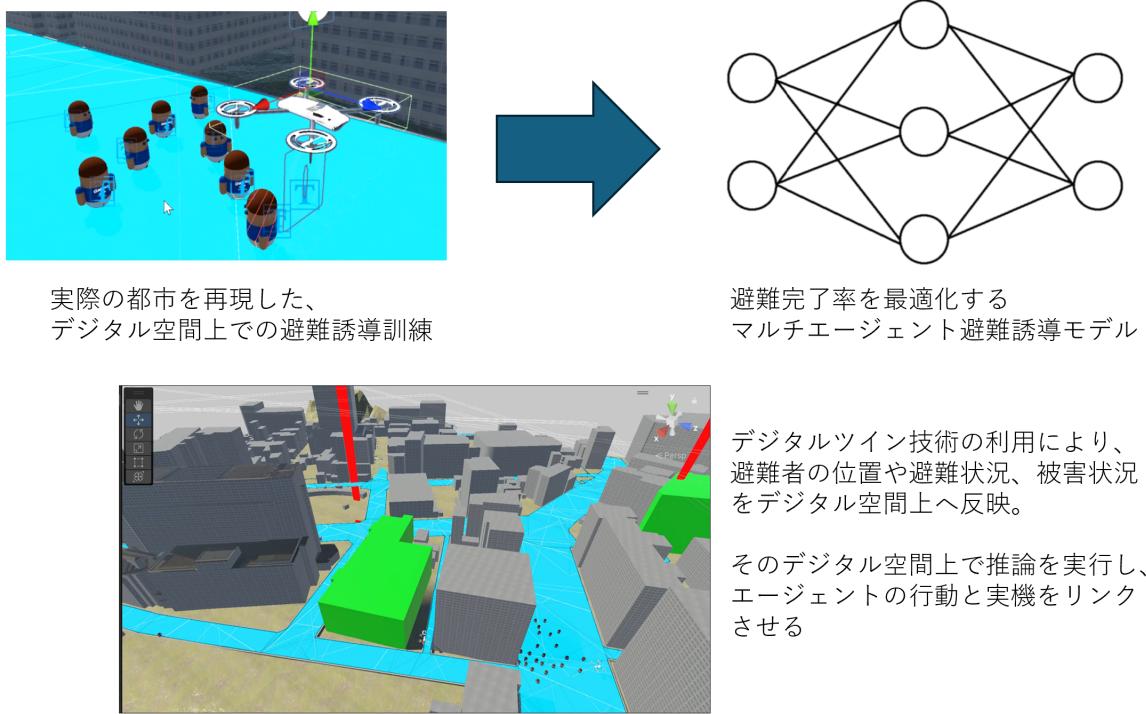


図3.1: 提案手法概略図

3.2 既存研究との新規性

研究背景で述べたとおり、本研究は既存の研究といいくつかの重要な相違点や新規性を有している。

まず、ドローンの防災活用はまだ研究が始まったばかりの新しい分野であり、本研究はその発展に寄与するものである。特に、複数のドローンを連携して運用するシステムに、AIや強化学習モデルを導入する点は、本研究の独自性を示す重要な要素である。

さらに、本研究では都市モデルを活用した訓練環境を構築し、デジタルツイン技術を通じて現実環境における運用を想定している。このように、現実世界での実用性を考慮した研究は、防災分野においても新しい試みである。

また、本研究は避難ビルの収容定員など、経路条件以外の要素を考慮した避難誘導モデルの作成にも取り組んでいる。従来の研究の多くが、避難者自身の行動最適化を通じて避難完了率の向上を目指しているのに対し、本研究では避難完了率を最適化できる避難誘導方策そのものを追求している点で特徴的である。

以上のような取り組みにより、本研究は現実世界での応用可能性を持つ動的な津波避難誘導システムの実現を目指している。

3.3 実験概要

本研究では、津波避難誘導問題を解決するために、マルチエージェント強化学習を用いたドローン避難誘導システムを提案する。本研究では、この問題を **1. 避難者探索タスク** と **2. 避難所誘導タスク** の 2 つの課題に分け、それぞれのタスクを解決するためのエージェントモデルを Unity 上のシミュレーションにより構築する。エージェントの訓練環境は実際の道路状況や避難所配置に限りなく近づけるため、都市モデルを活用したデジタルツイン環境を利用する。その後訓練済みエージェントモデルを利用した場合とルールベースで行動するエージェントを利用した場合それぞれのタスク遂行能力を評価するため、同一環境で比較シミュレーション実験を行う。なお、**2. 避難所誘導タスク**においては、ドローンエージェントの誘導がない場合、つまり避難者のみで避難行動を行う場合との比較も行う。その実験結果から、最終的な避難完了率の推移や経過時間などの指標を用いて、提案手法の効果検証と実現可能性を評価する。

3.4 シミュレーション前提条件

3.4.1 都市モデルの選定と避難所の配置条件

環境としては、下記 3 つの都市の都市モデルを PLATEAU SDK for Unity^{*1} を使い 3D 空間上に実際の都市環境に近いシミュレーション環境を再現する。なお、都市の選定基準については、3.1 章にて述べた想定場面を考慮するため下記の選定基準をもって決定した。

- 南海トラフ等で津波被害が想定されている沿岸地域であること
- 自治体の津波避難のハザードマップが参照可能であること
- 地元住民以外にも多数の観光客が見込まれる、比較的規模の大きな地域であること
- 津波避難ビルあるいは津波避難タワーが整備されている地域であること

以上の条件を元に、下記 2 つの都市をモデル都市として選択した。

1. 神奈川県横須賀市市役所本庁舎周辺沿岸地域
2. 静岡県沼津市沼津港周辺の一部地域

都市モデルと実際の避難ビル（避難タワー）との位置付けは、自治体公表のハザードマップ [19] [20] より確認し、都市モデル上で指定した。各モデル都市におけるシミュレーション対象範囲は以下地図3.2と地図3.4の赤枠で示した範囲とする。

^{*1} PLATEAU: プラトーは、国土交通省が主導する日本全国の 3D 都市モデルの設備・オープンデータ化プロジェクト

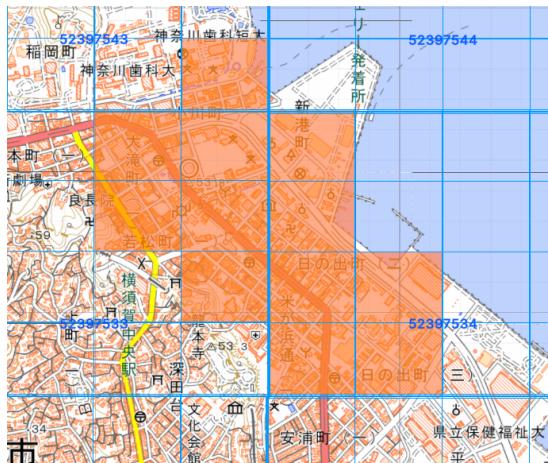


図3.2: 横須賀市でのシミュレーション範囲



図3.3: 対象範囲の横須賀市のハザードマップ

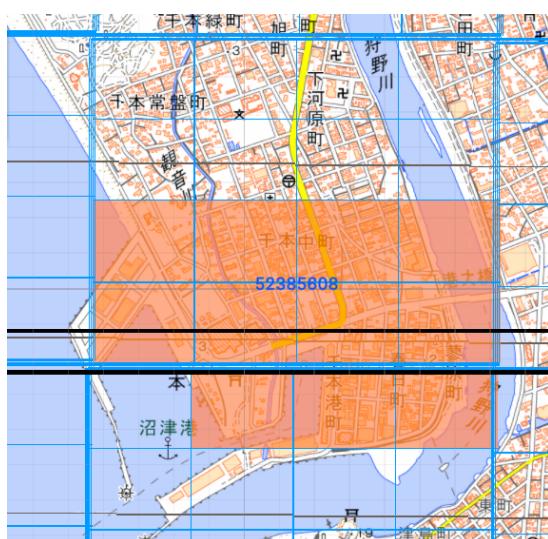


図3.4: 沼津市でのシミュレーション範囲

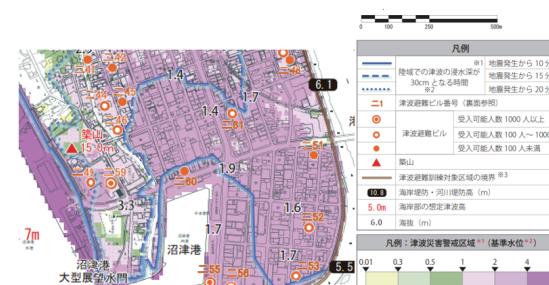


図3.5: 対象範囲の沼津市ハザードマップ



図3.6: 構築したシミュレーション環境の例

なお, 環境の制限時間は, 内閣府が公表している南海トラフ巨大地震における各地域の津波到達予想時間のデータ [21] を参考に下記の範囲内でエピソード毎にランダムに決定されるものとする.

3.4.2 避難者の前提条件

避難者の初期出現位置は環境内の道路上にランダムに配置するものとする. 避難者の移動方法は内閣府が公表している津波避難ガイドラインに基づき徒歩移動ないしは自転車による移動を想定する. そのため避難者の移動速度は, 1m/s から 3.4m/s の範囲内でランダムに設定する. 移動経路については, ナビゲーションメッシュにより指定位置までの道路上における最短経路を計算し, 各避難者はその経路に従って移動するものとする. 環境内に出現する避難者の総数は予め固定するものとし, 今回の実験では 200 名前後とした.

3.4.3 避難所収容人数の前提条件

避難誘導のタスク実験で扱う, 各避難所の収容人数については, 出現させる避難者が全て収容できるように避難所毎に均等に設定するものとする. これは, 第 2 章でも述べた収容定員を超過し, 適切な避難が行えない可能性があることを考慮し, 1 つの避難所に大量の避難者が殺到しても, 避難完了とするのを避けるためである. また, 後述するエージェントが誘導先の避難所を決定するに当たり, 自身の誘導人数と避難所の収容人数を考慮させるためである.

	制限時間 (秒)	エージェント数	避難所数 (設定収容人数)	出現避難者総数
横須賀市	1800~2400	4	4 棟 (50 人/1 棟)	200
沼津市	240~1800	16	16 棟 (13 人/1 棟)	208

表3.1: 各シミュレーション環境の前提条件

3.4.4 エージェントの前提条件

エージェントの訓練および, マルチエージェントモデルの作成は, 都市ごとに避難所の配置分布や道路状態といった環境条件が異なるため, 各都市ごとに行うものとする. シミュレーションにおいて, エージェントの初期位置は, 避難者の初期位置と同様に環境内の道路上にランダムに配置するものとする. なお, 出現するエージェントの数は, 環境内の避難所 1 つあたりにつき 1 機とする. 移動方法の詳細は後述する各実験の章にて述べる. エージェントは自身の移動が完了するごとに決定を要求し, 環境の観測を行った後, 行動を決定する. なお, 強化学習アルゴリズムには MA-POCA を利用する.

3.5 避難者探索タスク実験方法

この実験ではエージェントは環境内の避難者を探索し, 制限時間以内にできるだけ多くの避難者を見つけるタスクを行う. エピソード開始時, エージェントは環境内のランダムな道路上に配置される. その後エージェントは観測として, 自身の環境内に位置情報と移動速度, 現在発見した避難者の人数, 制限時間と経過時間, 他のエージェントの位置情報を取得する. またエージェントはレイキャスト^{*2}観測により, 自身の付近に避難者がいる場合, その避難者の位置情報を観測することができる. その後, エージェントは行動として, 自身の移動速度を 1.0 m s^{-1} から 2.0 m s^{-1} の間で移動速度を出力する. また, 現在位置からの移動量を半径50 m 以内の範囲で決定し, 移動を開始する. 避難者は半径60.0 m 以内でエージェントを視認できる場合, そのエージェントを追従し, エージェントの報酬として $\frac{1}{n}$ の正の報酬を得る. 制限時間を超えるか全ての避難者が発見された時点でシミュレーションのエピソードは終了する.

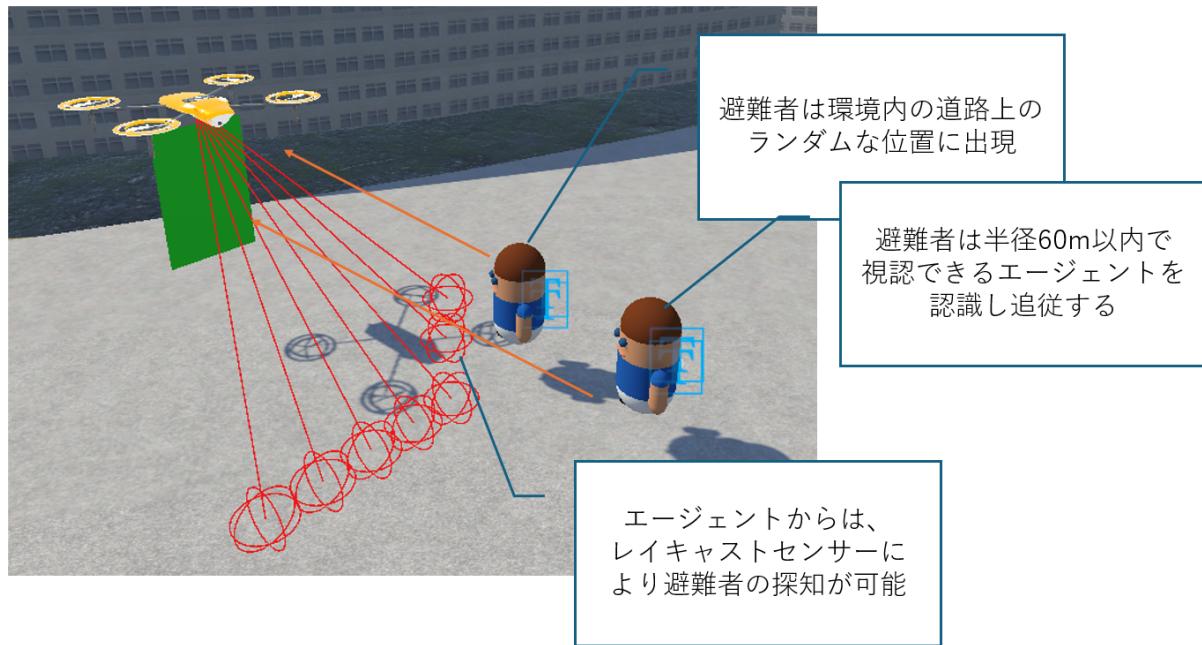


図3.7: 避難者探索タスクのイメージ図

エージェントの観測 エージェントは環境内の以下の情報を観測することができる.

- 自身の位置情報 (X,Y,Z 座標)
- 自身の移動速度 (浮動小数値)

^{*2} レイキャスト (Raycast) は, コンピュータグラフィックスや物理エンジンで使用される技術であり, 特定の方向に仮想的な「線 (レイ)」を発射して, それがどのオブジェクトに当たるかを検出する手法. 検知対象オブジェクトの位置情報を取得できる.

- 現在発見した避難者の人数
- 現在追従している避難者の平均移動速度
- 制限時間と経過時間
- 他のエージェントの情報
 - 他のエージェントの位置情報 (X,Y,Z 座標)
 - 他のエージェントが発見した避難者の人数

エージェントの行動 エージェントは観測情報に基づいて以下の行動を連続値として取ることができる.

- 移動速度 (1.0 m s^{-1} から 2.0 m s^{-1} の間での連続値)
- 現在位置からの移動量 (半径50 m 以内の範囲での連続値)

なお, エージェントが行動として出力した移動量に基づき, 移動先の座標を決定するが, 移動先の座標はナビゲーションメッシュ上の道路上に限定するものとするため, 計算した移動先の座標がナビゲーションメッシュ上にない場合は最寄りのナビゲーションメッシュ上の座標位置に移動するものとする.

エージェントの報酬 各エージェントは発見した避難者の人数に応じて $\frac{1}{n}$ の正の個別報酬を得る. また, 同時にグループ報酬として, $\frac{1}{n}$ の正の報酬を得る.

評価と比較 この実験では, マルチエージェント強化学習を用いたエージェントモデルとルールベースで行動するエージェントモデルの 2 つの行動パターンを比較する. ルールベースで行動するエージェントモデルは, ランダムに移動速度と移動量を決定し, 避難者を探索するものとする. 以上の 2 つの行動パターンにおいて, 最終的な避難者の発見率とその推移などの指標を用いて, マルチエージェントモデルとルールベースモデルの有効性を評価する.

3.6 避難所誘導タスク実験方法

この実験ではエージェントは事前に割り当てられた避難者グループを指定された避難所まで誘導するタスクを行う. エピドート開始時, エージェントは環境内のランダムな道路上に配置される. そのエージェントの周辺に 10 人から 40 人の避難者がランダムな人数配置される. 次にエージェントは観測として自身の環境内での位置情報や割り当てられている避難者の人数, 各避難所までの移動距離や収容人数などの情報を取得する. その観測に基づいてエージェントは行動として, 自身の移動速度を 1.0 m/s から 3.0 m/s の間で, 誘導先である避難所を 1 つ決定し移動することができる. 環境内の各避難所には収容可能人数が設定されており, 避難者が避難所に到達するとその避難所の収容可能人数が減少する. 避難者はエージェントに追従し, 避難所に到達すると避難者は避難所に収容される. なお, 避難所に収容される避難者の数は避難所の収容人数を超えることはないものとする. もし, 避難時点でその避難

所の収容定員を超える場合、避難者はエージェントに追従し続け、次のエージェントの行動決定まで待機する。制限時間を超えるか全ての避難者が避難所に収容された時にシミュレーションのエピソードは終了する。

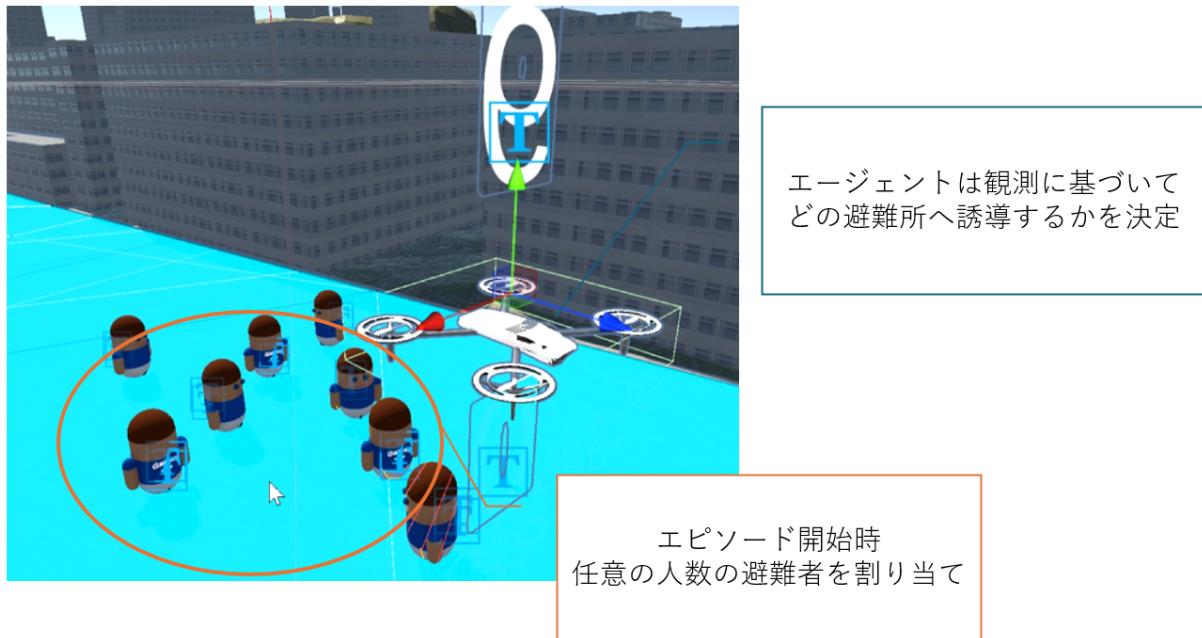


図3.8: 避難所誘導タスクのイメージ図

エージェントの観測 エージェントは環境内の以下の情報を観測することができる。

- 自身の位置情報 (X,Y,Z 座標)
- 自身の移動速度 (浮動小数値)
- 割り当てられている避難者の人数
- 避難者グループの平均移動速度
- 各避難所の位置情報 (X,Y,Z 座標)
- 各避難所までの移動距離
- 各避難所の現在の収容可能人数
- 他のエージェントの情報
 - 他のエージェントの位置情報 (X,Y,Z 座標)
 - 他のエージェントが移動する避難所の位置情報 (X,Y,Z 座標)
 - 他のエージェントが誘導している避難者の人数

エージェントの行動 エージェントは観測情報に基づいて以下の行動を取ることができる。

- 移動先の避難所
- 自身の移動速度

エージェントの報酬 各エージェントは誘導した避難所に自身に割り当てられている避難者が到達するとその人数に応じて $+1$ の正の個別報酬を得る。また、グループ報酬として、シミュレーション終了時点での最終的な避難完了率を計算し、その値に応じて $0 \sim 1$ の正のグループ報酬を得る。

評価と比較 この実験では、マルチエージェント強化学習を用いたエージェントモデルとルールベースで行動するエージェントモデル、避難者単独行動のパターンの 3 つの行動パターンを比較する。ルールベースで行動するエージェントモデルは、自身から最も近い受け入れ可能な避難所までの最短経路を計算し、避難所に到達するまでの移動速度を一定に設定するものとする。避難者単独のパターンでは、各避難者は自身から最寄りの避難所までの最短経路を計算し、その経路に従って移動するものとする。なおこの時避難者は、移動先の避難所の収容人数を知ることはできず、避難所に到達した段階で収容可能人数を超える場合、次の最寄りの避難所に向かうものとする。

以上の 3 つの行動パターンにおいて、最終的な避難完了率、経過時間ごとの避難完了率の推移、の指標を用いて、マルチエージェントモデルの有効性を評価する。

第4章

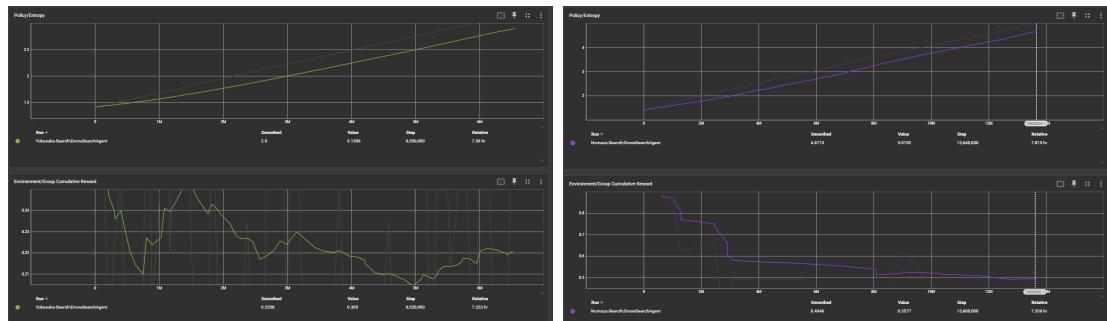
実験結果と考察

本章では、前章で述べた提案手法の有効性を検証するために行ったシミュレーション実験の結果について報告する。また、各実験結果に基づき、提案手法が持つ課題やその改善の可能性について考察する。

4.1 避難者探索タスク実験

4.1.1 モデル学習結果

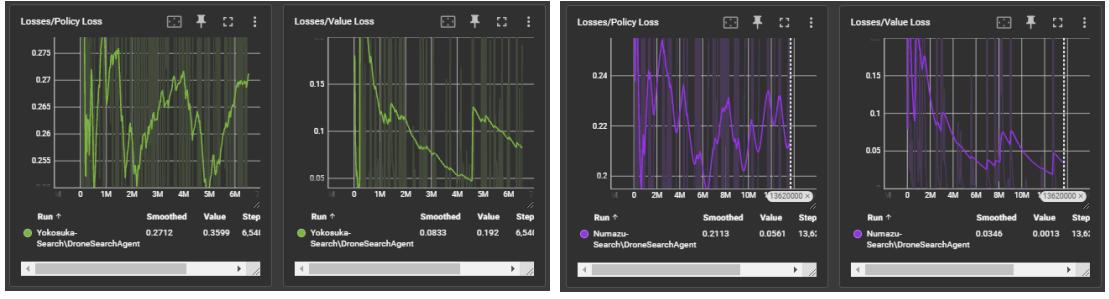
図4.1a～図4.2bは本実験における各都市環境のマルチエージェントモデルの学習過程のグラフである。エントロピーの推移、グループ報酬の推移、ポリシー関数の平均損失、価値関数の平均損失のグラフを示す。



(a) 横須賀市環境での訓練結果

(b) 沼津市環境での訓練結果

図4.1: 両都市モデルでのエントロピー (上) とグループ報酬 (下) の推移



(a) 横須賀市環境での訓練結果

(b) 沼津市環境での訓練結果

図4.2: ポリシー関数の平均損失 (左) と価値関数の平均損失 (右)

まず、図4.1aと図4.1bのエントロピーの結果であるが、これはモデルの行動決定のランダムさを示す指標であり、この値が低い程行動出力がランダムでない、すなわちモデルの学習した方策に基づいて行動を出力していると見なすことができる。しかし、両方の都市において、この値が学習の経過とともに上昇していることが確認でき、その値は学習終了時までに横須賀市のケースでは 1.5 から 3.0 程度、沼津市のケースでは 1.5 から 4.5 程度と高い値を示した。また、グループ報酬の推移であるが、両都市ともに学習が進むにつれ減少傾向にあり、訓練課程での報酬の最大化が達成されていないことがわかる。横須賀市のケースでは学習後半から若干ではあるが獲得グループ報酬が微増してきている。一方、沼津市のケースでは、学習終了時までに報酬が減少し続けていることがわかる。訓練開始から終了までのグループ報酬の推移は、横須賀市のケースでは 0.3 から 0.22 程度、沼津市のケースでは 0.87 から 0.5 程度に落ちていた。

次に図4.2aと図4.2bのポリシーと価値関数の平均損失のグラフを見る。(左) のポリシー関数の平均損失のグラフは、エージェントの方策がどの程度変化しているかを示すグラフで学習が成功するにつれ、減少することが期待されるグラフである。両都市ともに、安定して減少しているとは言い難く、学習終了時までに収束していないことが確認できる。ただし、沼津市のケースでは若干ではあるが、学習終了時までに振れ幅はあるものの損失が減少傾向にあることが読み取れる。訓練開始から終了までのポリシー関数の平均損失の値は、横須賀市のケースでは 0.3 から 0.25 まで減少した後に 0.27 まで損失が増加した。沼津市のケースでは、0.32 から 0.05 まで減少した。最後に、(右) 価値関数の平均損失のグラフであるが、これはモデルの予測精度を示すグラフであり、エージェントの学習中は増加し、累積報酬が安定すると減少するグラフである。これを読み解くと、両都市ともに学習初期段階は増加傾向にあるが、学習の進行につれ減少傾向にあるのが読み取れる。訓練開始から終了までの価値関数の平均損失の値は、横須賀市のケースでは 0.18 から始まり 0.38 程度まで上昇した後、最終的には 0.08 まで減少した。沼津市のケースも同様の値の範囲で減少傾向を示した。価値関数の損失が減少しているにもかかわらず、累積報酬が減少している場合、エージェントの行動方針が誤った方向に収束している可能性がある。

4.1.2 実験結果

本節では、避難者探索タスクの実験結果を報告する。本実験では、マルチエージェントモデルとの比較実験と合わせて以下の 2 パターンにおける最終的な避難者探索完了率の推移を元に、訓練したマルチエージェントモデルモデルの有効性を評価する。なお、シミュレーションの制限時間は、各都市ごとに異なるが、100 秒毎に段階的に増やしていく形で設定し、記録した。

1. ルールベースでの探索
2. 学習済みマルチエージェントモデルによる探索

横須賀市のケース

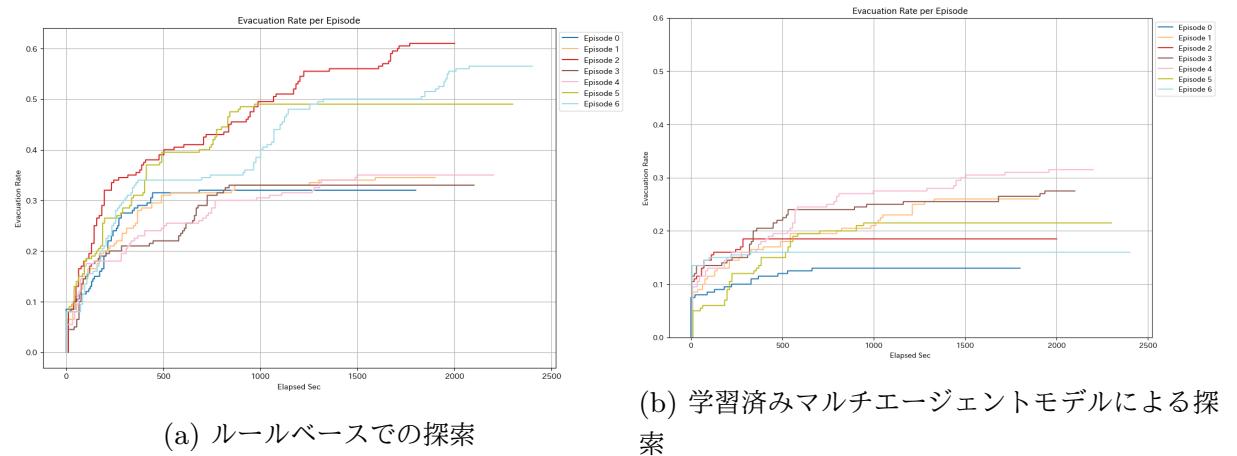


図4.3: 横須賀市のケースにおける避難者探索完了率の推移

横須賀市のケースでは、全体的にマルチエージェントモデルによる探索よりも、各エージェントがルールベースでランダムに探索する方法の方がエピソード終了までに高い発見率を示した。ルールベースでの探索の方が最終的な発見率が 33% から 55% 程度なのに対し、マルチエージェントモデルによる探索はほとんどのエピソードにおいて、20% から最大でも 30% 程度の発見率に留まった。経過時間当たりの発見率の上昇度合も、ルールベースでの探索の方が高い値を示しており、マルチエージェントモデルによる探索は、エピソード終了までに十分な数の避難者を発見できていないことがわかる。

沼津市のケース

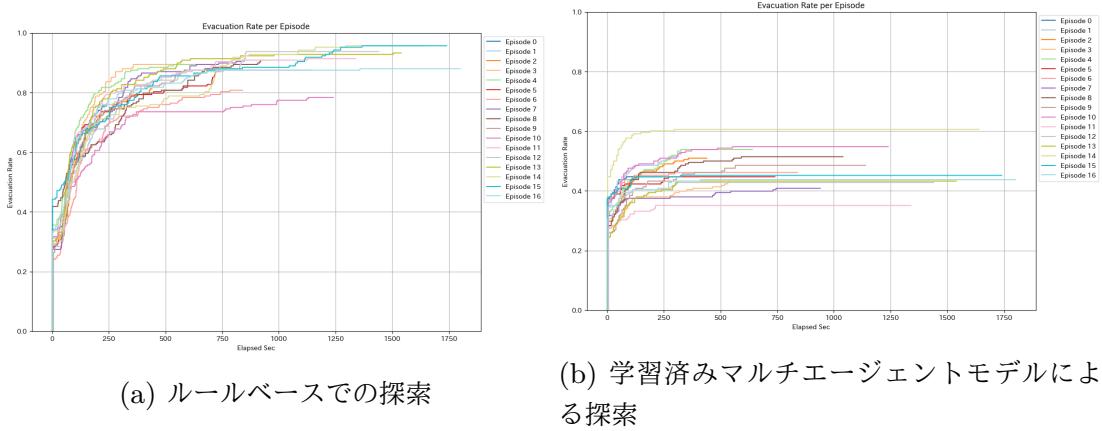


図4.4: 沼津市のケースにおける避難者探索完了率の推移

沼津市のケースでも横須賀市のケースと同様に,マルチエージェントモデルによる探索よりも,各エージェントがルールベースでランダムに探索する方法の方がエピソード終了までに高い発見率を示した. ルールベースでの探索が,多くのエピソードにおいて 70% から 85% 程度の発見率を示しているのに対し,マルチエージェントモデルによる探索は,40% 程度の発見率に留まった. ルールベースのみの結果に着目すると,横須賀市のケースよりも非常に高い発見率を示しており,エピソード終了までに最大で 90% 程度の避難者を発見できているケースがあるのが分かる.

4.1.3 結果の考察

実験では,マルチエージェント強化学習モデルとルールベースモデルの 2 つの行動パターンを比較し,避難者発見率およびその推移を評価した.

避難者探索のタスクにおいては,両都市ともにマルチエージェントモデルによる探索の方が,ルールベースでの探索に比べて避難者の発見率が低い結果となった. まず,結果として明らかになったのは,ルールベースモデルがマルチエージェントモデルよりも高い避難者発見率を達成した点である. 図4.3aおよび図4.4aから,ルールベースモデルは横須賀市および沼津市の両環境で,最終的に 50% から 90% の発見率を示しており,エピソード中の発見率の増加傾向も顕著であった. 一方,マルチエージェントモデルでは,多くのエピソードで発見率が 20% から 40% 程度に留まり,ルールベースモデルに劣る結果となった. ただし,横須賀市におけるケースでは図4.3aおよび図4.3bより,今回のマルチエージェントモデルが優れた点として最終的な発見率のバラつきがルールベースの場合よりも小さい. ルールベースでは,今回のシミュレーション回数 7 回のうち,発見率が 30% 60% 程度と,約 30% 程度の開きがある. 一方マルチエージェントモデルの場合は,発見率が 12%~30% 程度とその開きは 18%

程度となっており、結果としての精度としては低いが、ルールベースよりも安定した結果を期待できる可能性がある。

この結果の原因として考えられる要因は以下の通りである。まず、マルチエージェントモデルの学習過程において、エントロピーが学習の進行とともに上昇している点が挙げられる（図4.1aおよび図4.1b参照）。エントロピーはエージェントの行動選択のランダムさを示す指標であり、その値が高い場合、行動方針が収束せず、適切な探索戦略が確立できていないことを示している。これに加え、報酬設計において、個別報酬およびグループ報酬が避難者発見数に直接比例しているため、エージェントが短期的な目標（局所的な避難者発見）に偏り、グローバルな探索戦略を学習できていない可能性がある。

次に、ポリシー損失および価値関数損失の推移（図4.2aおよび図4.2b参照）を見ると、特にポリシー損失が学習終了時まで安定して収束していない点が観察された。これは、エージェントが適切な方策を十分に学習できていらず、環境内で効果的な行動を選択できることを示している。一方、価値関数損失は学習が進むにつれ減少しており、エージェントが環境内の状態価値をある程度正確に予測していることが分かる。しかし、この予測精度の向上が報酬の最大化には結びついていないことから、モデルの報酬設計にさらなる調整が必要である。

ルールベースモデルがマルチエージェントモデルを上回った理由として、環境特性の影響も考慮する必要がある。今回の環境では避難者の出現位置は、各都市の道路状にランダム出現するという条件であった。そのため避難者の出現ポイントが環境内で均一である可能性が高く、ランダムに移動するルールベースモデルが高い発見率を達成しやすい条件となっていた可能性がある。一方で、マルチエージェントモデルは探索戦略の収束が不十分であったため、これらの単純な条件に適応しきれなかったと考えられる。ここ部分に関しては、住宅街等の狭い道路より、国道等の大通りの方が路上に存在する避難者の割合は高いはずであるため、シミュレーション条件の再考が必要である可能性がある。

今後の改善点としては、まず報酬設計の見直しが必要である。例えば、エージェントが効率的な探索を行えるよう、未探索エリアの探索や他エージェントとの協調行動を促進する報酬を追加することが考えられる。また、エントロピーの上昇を抑えつつ探索と収束のバランスを取るために、ハイパーパラメータの調整や方策正則化を導入することが有効と考えられる。

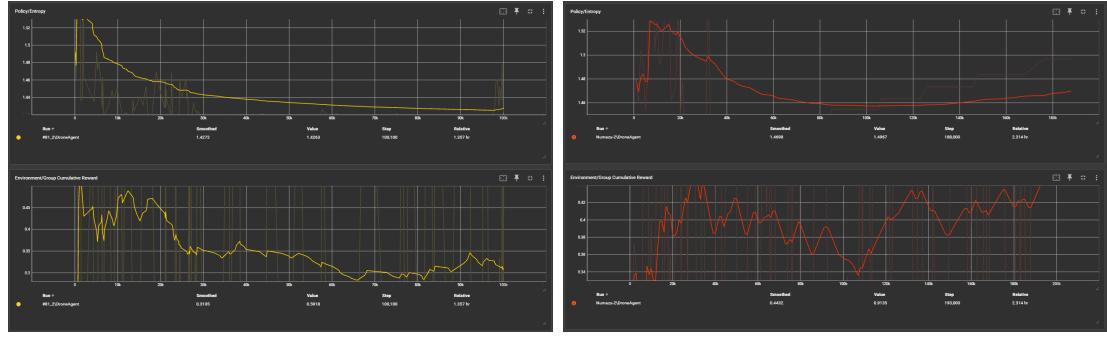
以上のように、本研究における避難者探索タスクの結果から、マルチエージェントモデルの有効性を最大化するためには報酬設計や学習設定のさらなる最適化が求められることが示唆された。

4.2 避難所誘導タスクの結果

4.2.1 モデル学習結果

図4.5a～図4.6bは、本実験における各都市環境のマルチエージェントモデルの学習過程のグラフである。エントロピーの推移、グループ報酬の推移、ポリシー関数の平均損失、価値関

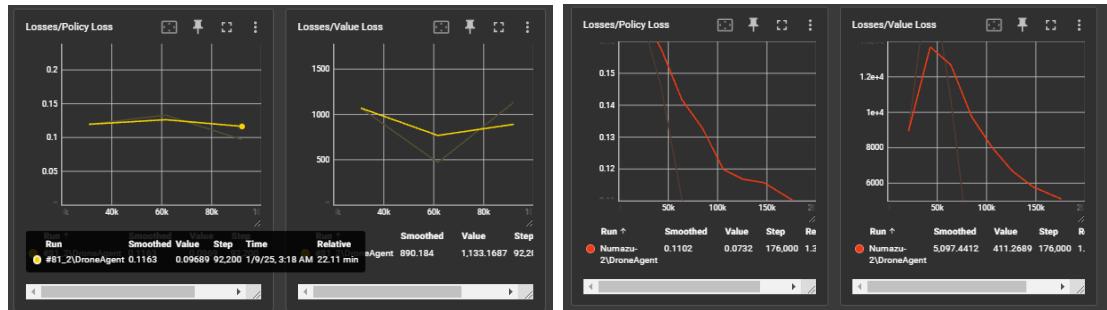
数の平均損失のグラフを示す.



(a) 横須賀市環境での訓練結果

(b) 沼津市環境での訓練結果

図4.5: 両都市モデルでのエントロピー (上) とグループ報酬 (下) の推移



(a) 横須賀市環境での訓練結果

(b) 沼津市環境での訓練結果

図4.6: ポリシー関数の平均損失 (左) と価値関数の平均損失 (右)

どちらの都市においてもエントロピーが学習が進むにつれ減少しており, 学習によりモデルの行動が収束していることがわかる. 最終的な数値の大小としては, 横須賀市での学習環境の方が沼津市に比べてエントロピーが低く, モデルの行動出力としては前者の環境の方が安定性があると言える.

次にグループ報酬の推移について見ると, 横須賀市の環境においては, エピソードの進行に伴いグループ報酬が減少してしまっている. 対して, 沼津市の環境においては, 横須賀市の環境よりもバラつきはあるものの, 全体としては学習が進むにつれて微増しており, エントロピーの結果とも合わせると良い方向に, グループ報酬の最大化にむけて方策が収束していったことが分かる.

しかし, 最終的なグループ報酬の値に着目すると, 両方の環境において 0.3 から 0.45 程度の報酬しか得ておらず, 訓練全体を通してあまり良い結果が得られていないことがわかる.

また, モデルの予測精度を示す価値関数の平均損失のグラフの値が, 横須賀市の場合は 1000, 沼津市の場合は 5000 程度と高い値を示していることがわかる. 価値関数の損失の推移は, 一般に報酬が安定すると減少するが, 横須賀市の場合はほぼ横這いとなっており,

図4.5aのグループ報酬の推移と合わせると、モデルの学習が十分に進んでいないことがわかる。沼津市の場合は、価値関数の損失は学習の経過と共に減少しているように見えるが、その値は高い状態が続いている。モデルの予測精度についても十分な精度が得られていないことがわかる。

4.2.2 実験結果

本節では、避難所誘導タスクの実験結果を報告する。本実験では、マルチエージェントモデルとの比較実験と合わせて以下の3パターンにおける最終的な避難完了率や時間経過ごとの避難完了率の推移を元に、訓練したマルチエージェントモデルモデルの有効性を評価する。なお、シミュレーションの制限時間は、各都市ごとに異なるが、100秒毎に段階的に増やしていく形で設定し、記録した。

- (a) 避難者のみで避難行動を行う場合
- (b) ルールベースで行動するエージェントモデルによる誘導
- (c) 学習済みマルチエージェントモデルによる誘導

横須賀市のケース

シミュレーション制限時間は1800秒から2400秒の間で、エピソード毎に100秒ずつ増加する形で検証した。以下に、横須賀市のケースにおいて、各ケース毎に複数回シミュレートした結果の経過時間ごとの避難完了率の推移を示す。横軸がシミュレーション経過時間(秒)であり、縦軸が避難完了率である。

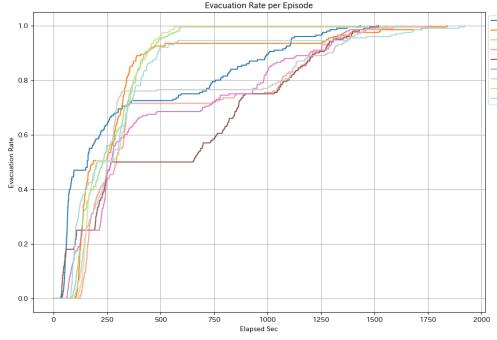


図4.7: (a). 避難者のみで避難行動を行う場合

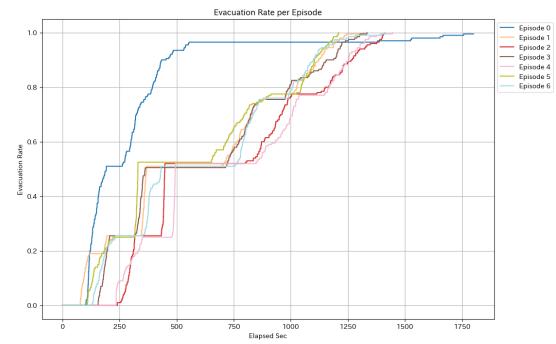


図4.8: (b). ルールベースでの誘導の場合

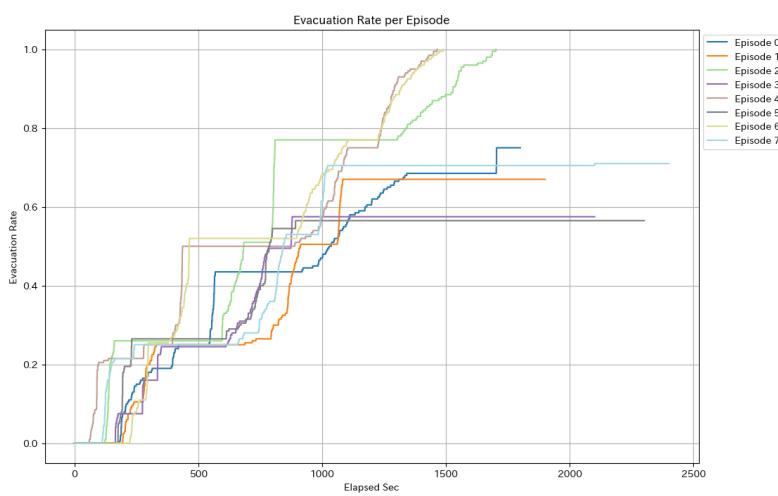


図4.9: (c). 学習済みマルチエージェントモデルによる誘導の場合

横須賀市における環境においては,(c) マルチエージェントモデルによる誘導よりも,(b) ルールベースまたは (a) 避難者のみで避難行動を行う場合の方が避難完了率の変化が速く,多くのエピソードにおいて最終的な避難完了率が 90% を超えており,高いことがわかる. マルチエージェントモデルによる誘導では,多くの場合で避難完了率が 60% から 70% 程度で収束しており,多くのケースで避難者全員を制限時間以内に避難所まで誘導することを達成出来なかった. また, ルールベースと避難者のみでの結果のグラフに着目すると, 避難者のみで行動する場合は, 避難率が 100% になるまでに要した時間が 1500 秒前後なのに対し, ルールベースでの誘導を導入した場合は 1250 秒前後と, 出現した避難者全員が避難完了するまでの時間が数分程度短縮されていることがわかる.

沼津市のケース

シミュレーション制限時間は 240 秒から 1800 秒の間で, エピソード毎に 100 秒ずつ増加する形で検証した. 以下に, 沼津市のケースにおいて, 各ケース毎に複数回シミュレートした

結果の経過時間ごとの避難完了率の推移を示す。横軸がシミュレーション経過時間(秒)であり、縦軸が避難完了率である。

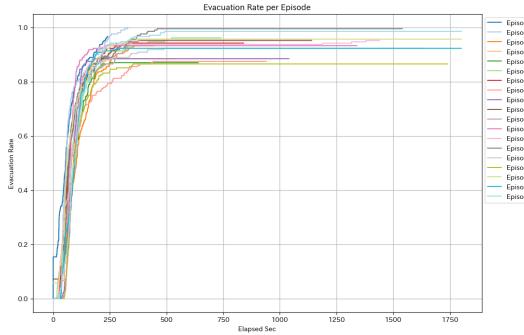


図4.10: (a). 避難者のみで避難行動を行う場合

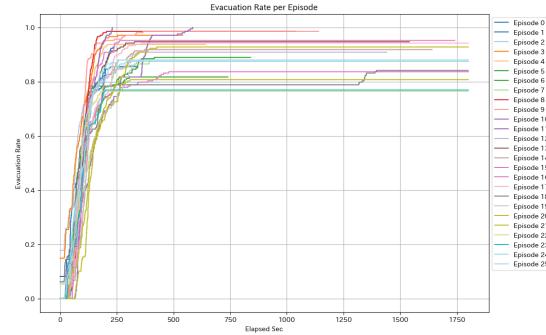


図4.11: (b). ルールベースでの誘導の場合

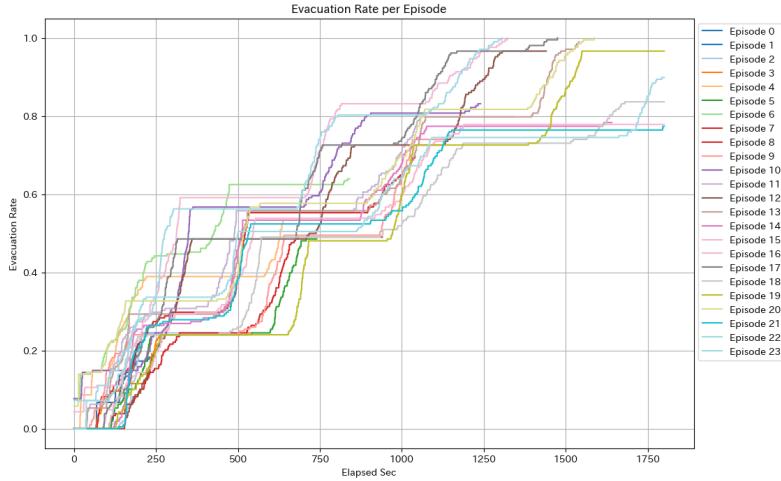


図4.12: (c). 学習済みマルチエージェントモデルによる誘導の場合

沼津市のケースでは、(a) 避難者のみで避難行動を行う場合と (b) ルールベースでの誘導を導入時の避難完了率の推移に大きな差は見られず、どちらのケースも多くのエピソードで、短時間で避難完了率が 90% 以上に達しており、全体的に迅速な避難が実現されている。避難者のみで行動を行う場合、避難完了率が 90% を超えるまで開始から 250 秒以上経過してからが多いが、ルールベースでの誘導時は若干ではあるが 250 秒以下で避難完了率 90% を達成しているケースが多く、前者よりも避難完了率の上昇が早いことがわかる。一方で、学習済みマルチエージェントモデルによる誘導時の避難完了率の推移を見ると、避難者のみで避難行動を行う場合やルールベースでの誘導を導入時と比較して、避難完了率の上昇が遅いことがわかる。制限時間が短いエピソードでは避難完了率が 20% から 40% 程に留まっている他、避難完了率が 90% を超えるまでに 1200 秒以上必要なエピソードが多く見られ、他のケースと比較して遅い避難完了率の推移が見られる。

4.2.3 結果の考察

避難所誘導タスクにおいて、図4.9から図4.12の結果から今回訓練したマルチエージェントモデルでは、多くの場合において避難完了率が90%を超えることができず、避難者全員を制限時間内に避難所まで誘導することが難しいことがわかった。また、経過時間あたりの避難完了率の伸び率からも、ルールベースでの誘導や避難者のみでの避難行動を行う場合と比較して、今回作成したマルチエージェントモデルによる誘導の方が遅いことが示された。これは、図4.5の学習結果からもわかるように、モデルの学習が不十分であることが原因であると考えられる。訓練全体を通じて、高い避難完了率を達成できるような方策をエージェントが経験できず、誘導人数や現在位置、避難所の収容人数に基づいた適切な誘導先の避難所を選択できなかったと考えられる。また、モデルの予測精度を評価する指標の価値関数の平均損失の値が非常に高いことから、モデルの予測精度も低いことが言え、エージェントが報酬を最大化する適切な行動を出力できないということが言えるだろう。加えて、損失関数の減少が収束していないことからも、モデルの学習が不十分であると思われる。これらは、訓練時間の不足や、ニューラルネットワークのハイパーパラメータの調整にまだ改善の余地があることを示しており、今後の課題として挙げられる。

また、エージェントの行動過程を観察分析すると、近隣の受け入れ可能な避難所を選択するのではなく、遠方の収容人数が多い避難所を選択する傾向が多く見られた。このことが、他の方法と比較して遅い避難完了率の推移に繋がったと考えられる。また、図4.13のように、全エージェントが1箇所の避難所に殺到してしまうケースも散見された。



図4.13: 1箇所の避難所に殺到するエージェントの行動過程

この原因としては、エージェントの行動決定時に、避難所と自身の距離に応じた報酬を与えていないことが原因で、エージェントが距離に応じた適切な避難所を選択できなかった可能性が考えられる。また、報酬の付与のタイミングも問題であった可能性がある。今回グループ

報酬はエピソード終了時の全体の避難完了率を報酬としていた。また個別報酬は、各エージェントの避難所選択時ではなく、避難者が避難所に到達した際に逐次報酬を与えていた。このため、エージェントは避難所に到達するまでの行動に対して報酬を受け取ることができず、適切な避難所を選択するための情報が不足していた可能性がある。

沼津市の方が横須賀市よりも全体的な避難完了率が高いこと、経過推移が早いことが図4.7から図4.12の結果からわかる。これは、沼津市の避難所配置が図4.14bのように4.14a横須賀市よりも個数が多い他、対象範囲内にあまり位置に偏りなく避難所が配置されていることが影響していると考えられる。横須賀市の場合は、対象範囲の両端それぞれに2か所の避難所が設けられているが、沼津市の場合は、横須賀市ほど避難所の配置は偏っておらず、その配置は放射状に配置されている他、近距離に他の避難所があるといった特性がある。この様な都市ごとの環境的要因から1棟あたりの収容人数が横須賀市よりも少なく設定されているのにも関わらず、避難者が直ぐに近隣の避難所までたどり着けた傾向があり、全体的な避難完了率が横須賀市よりも高い結果となったと考えられる。

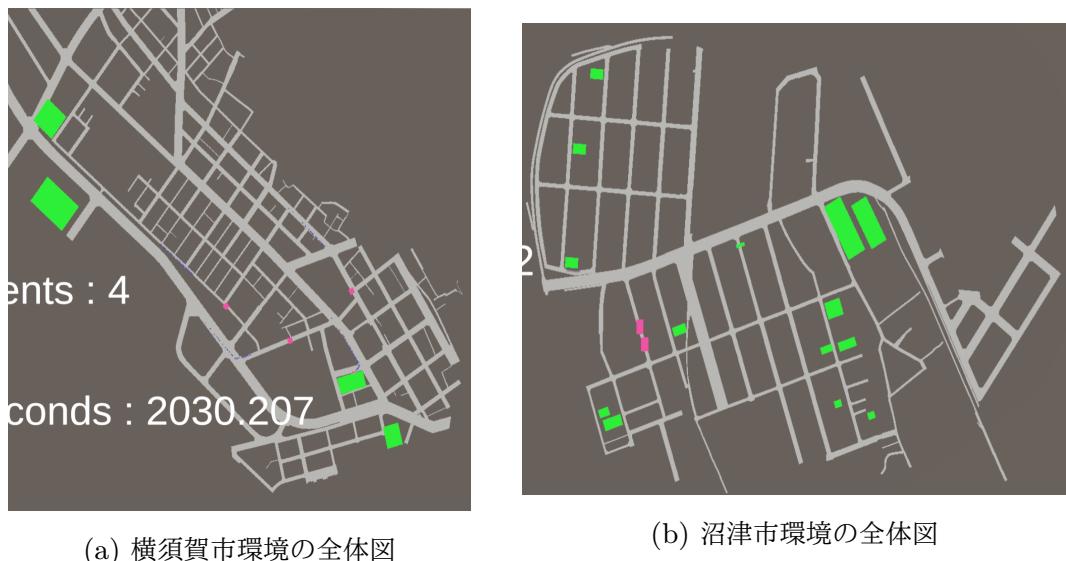


図4.14: 各都市の全体図 (緑: 避難所, 灰色: 道路)

第5章

結論

本章では、本研究で提案したマルチエージェントドローンによる津波避難誘導システムの実現可能性について、実験結果および我が国における災害対策の現状を踏まえてまとめる。また、本研究の成果を基にした今後の展望についても述べる。

5.1 実験のまとめ

本研究は、マルチエージェント強化学習を用いたドローンによる津波避難誘導システムを提案し、その効果を3D都市モデルを活用したシミュレーション実験で検証した。実験では、津波避難誘導のタスクを**1. 避難者探索と収集**と**2. 避難者群衆の誘導**の2つのタスクに置けるマルチエージェントモデルを作成し、その効果を検証した。その結果から、以下の点が明らかとなった。

ルールベースでのドローンエージェントの有効性 まず、ルールベースでのドローンエージェントが避難者の探索および誘導において一定の有効性を示した点である。避難者探索のタスクにおいては、都市の道路状況やエージェントの初期位置、エージェントの機数により結果に変動はあるが、ランダムに行動するドローンエージェントの場合でも比較的短時間で35%から最大で80%程度の避難者を発見、エージェントの各個において誘導すべき群衆を形成することができた。また、群衆の避難所誘導タスクにおいては、避難所までの最短経路を進む避難者のみで行動するケースよりも、ルールベースでの誘導を実施する方が若干ではあるが避難完了を速く行わせることができることが確認された。

ただし、これらのシミュレーション条件にはいくつか課題が残されている。探索モデルの場合は、避難者の出現位置の前提条件として、環境内の道路上にランダム偏りなく出現するという条件があり、実際の都市空間においては住宅街や大通りなど場所により避難者の人数分布は偏る可能性がある。避難者の出現分布を偏らせた場合での検証が必要である。また、避難所誘導モデルにおいては、エージェントの初期位置の違いにより、エピソード毎の最終的な避難完了率にバラつきがある点や、避難所毎の収容人数に偏りを持たせた場合での検証が

必要である。また、避難者の人数規模についても再考が必要である。本研究ではサンプルとして200名前後での各タスク遂行実験を行ったが、実際の各都市における想定される避難者数を考慮したさらに大規模な検証が必要である。

マルチエージェントモデルの課題 本研究では、探索と誘導どちらのタスクにおいても、今回作成したマルチエージェントモデルはルールベースでの性能には及ばなかった。これは、モデルの学習が全体として上手くいかず、エージェントが適切な協調行動を行う方策を学習できなかつたためである。学習が上手くいかなかつた要因としては複数考えられるが、モデルの学習過程を分析すると次の様なことが考えられる。探索タスクにおいては、累積報酬が学習過程で増加せず、最終的に減少傾向にあった点と価値関数の平均損失が学習過程で減少している点が確認された。また、誘導タスクにおいては、累積報酬は沼津市のケースでは若干の増加傾向を示したもの、横須賀市のケースでは学習過程全体で減少傾向を示した。また全体として、価値関数の平均損失の値が大きく、モデルの予測性能が低いことが伺える。このことから、エージェントが訓練課程で誤った方策を学習してしまった可能性が高く、最終的な結果が良くならなかつたものと推察される。

5.2 ドローンによる津波避難誘導の実現可能性

ドローン（無人航空機）の津波避難における活用が既に我が国でも進められており一部の自治体では、運用段階に入っていることを紹介した。また東日本大震災以後、避難誘導において避難者のみならず、誘導にあたる人員も含めた人的被害を低減することの重要性が再認識されている現状がある。加えて、新型コロナウイルスによる政府の自粛要請も終わり、観光客数が再び増加傾向にある中、土地勘のない大勢の観光客も含めた避難者の津波避難行動については、津波避難ビルの配置や収容定員超過等の理由により、現状では十分な避難対策が行われているとは言い難い状況が先行研究で示された。このような状況において、津波避難誘導の一連のオペレーションをドローンによって代替することは、人的被害を低減する観点からも有効であると考えられる。本研究における実験結果が示すように、マルチエージェントニューラルネットワークモデルを用いたドローンの避難誘導には課題が残されているが、ルールベースでのドローンエージェントによる避難誘導は一定の効果が期待でき、先行研究事例も含め、津波避難誘導をドローンで代替できる可能性とその有効性を確認することができた。

5.3 今後の展望

本研究の結果を踏まえ、以下の方向性でさらなる発展が期待される。

まず、報酬設計の見直しが必要である。具体的には、避難者を発見した際の報酬だけでなく、未探索エリアの探索や協調行動に基づく報酬を導入することで、エージェントの探索効率を向上させることが可能である。また、エントロピーの制御を通じて、行動方針の収束を促進し

ながら適切な探索と利用のバランスを取る仕組みを設ける必要がある。

次に、シミュレーション環境をさらに現実に近づけることも重要である。本研究で構築した環境は、現実の地形や避難所配置を模倣したものであるが、気象条件やリアルタイムの人口動態データを取り入れることで、より現実的なシナリオでの検証が可能となるであろう。

さらに、実環境における検証も進めるべきである。例えば、自治体や研究機関と連携し、災害対応訓練の一環として提案システムを試験運用することで、その有効性を実証し、改良を行うことができる。また、複数ドローンのリアルタイム制御や通信の安定性を向上させるための技術的な工夫も求められる。

最終的に、本研究の成果は、津波避難誘導に限らず、風水害や地震など、様々な災害シナリオへの応用が期待される。マルチエージェント強化学習と自律型ドローンの組み合わせは、防災技術の新たな可能性を広げるものであり、今後の防災分野におけるさらなる研究と実用化が待たれる。

謝辞

まず、研究室で2年間、研究テーマ相談から、実験内容の決定、論文の着地点の相談まで、実際に多方面で終始多大なご指導を賜った三宅陽一郎先生に深く感謝を申し上げます。研究成果か思う様に進まない時期もありましたが、先生のご指導のおかげで、最後まで諦めずに研究を続けることができました。また本研究以外にも、産学連携プロジェクトの監督、昨年度のオープンハウス企画のご相談などにもご協力頂きました。心より感謝いたします。ありがとうございました。

この2年間の研究室活動を通じ、単に知識と技術力を広げただけでなく、ゲームAI技術を社会課題に応用できる可能性と有意義さ、そしてなにより面白さを知ることができました。これも、先生の研究室に所属し研究活動を行えたからこそ得られたものであると感じております。

また、リアルミーティングや自主的なゼミ、オープンハウスでの企画、外部コンペティションへの参加など、先生以外の研究室の皆様にも多大なるご協力を頂きました。また、日ごろの研究についてもアドバイスを賜りとても助かりました。この場を借りまして、心より感謝申し上げます。また、研究を続けるために支援をくださった家族にも感謝いたします。

実に様々な方々に支えられ、助けられ、この論文を完成させることができました。改めて、心より感謝申し上げます。ありがとうございました。

参考文献

- [1] 島内佑規. 津波避難タワーへの避難者数と収容人数の現状及び解決策の検討. 高知工科大学卒業論文, 2017.
- [2] 山田太郎, 佐藤花子, and 鈴木次郎. 観光客の津波避難経路選択について—鎌倉市腰越地区をケーススタディとして—. 都市計画報告集, 17(4):388–395, 2018.
- [3] 岡安章夫, 武若聰, 中野晋, 村上啓介, 荒木進歩, 森信人, 青木伸一, 今村文彦, 越村俊一, and 佐藤慎司. 津波防災に対する住民・海岸利用者の意識と対策立案者の認識との相違に関する調査. 海岸工学論文集, 54:1336–1340, 2007. A Questionnaire Survey on Discrepancies between Assumed and Actual Demands and Knowledge of Citizens for Tsunami Disaster Prevention.
- [4] 北原武嗣, 岸祐介, and 久保幸獎. 高低差を考慮した津波災害時の群衆避難における経路選択に関する一検討. 土木学会論文集 A1 (構造・地震工学), 69(4):I_1067–I_1075, 2013. 鎌倉市材木座沿岸部を対象とした津波避難シミュレーションを通じて、パーソナルスペースや高低差の考慮が避難行動に及ぼす影響を検討。.
- [5] 山田忠, 後藤雄太, and 松枝心路. 風水害における消防団員の人的被害の特徴—1969年から2018年までの災害を事例に—. 土木学会論文集 F6 (安全問題), 76(1):20–27, 2020.
- [6] 東日本大震災における警察官の殉職・行方不明に関する報告. 警察庁震災関連報告書, page 11, 2012. 平成24年3月11日現在のデータを含む.
- [7] 災害補償課. 東日本大震災に係る消防団員等の公務災害補償等の状況について(平成24年5月末日現在). 広報消防基金, (184):21–28, 7 2012.
- [8] 総務省・消防庁. 無人航空機の災害時における活用状況等調査について. 消防の動き, 2, 2022.
- [9] 杉安和也, 高橋秀幸, 横田信英, and 片山健太. 津波避難時の誘導を目的としたuav活用方法の検討. In 東日本大震災特別論文集 No.7, pages 7–10. 東北大学災害科学国際研究所, July 2018. 福島県いわき市での実証実験を含む.
- [10] 鈴木学, 浜克己, and 中村尚彦. 協調ドローンを用いた避難誘導支援システム. 計測自動制御学会論文集, 56(1):24–30, 2020. Vol.56, No.1, 24/30 (2020).
- [11] 高橋秀幸, 片山健太, 横田信英, 杉安和也, 北形元, and 木下哲男. Uavを活用した避

- 難誘導支援システムの設計と試作. In *FIT2018* (第 17 回情報科学技術フォーラム) , pages 363–364. 情報処理学会, September 2018.
- [12] 仙台市. 津波避難広報ドローン事業, 2023. 最終アクセス日: 2024 年 12 月 20 日.
- [13] Andrew Cohen, Ervin Teng, Vincent-Pierre Berges, Ruo-Ping Dong, Hunter Henry, Marwan Mattar, Alexander Zook, and Sujoy Ganguly. On the use and misuse of absorbing states in multi-agent reinforcement learning. *arXiv*, 2111.05992v2(cs.LG), 2022.
- [14] 三宅陽一郎. 人工知能の作り方——「おもしろい」ゲーム AI はいかにして動くのか. 技術評論社, 東京, 2016. ISBN: 978-4-7741-8627-6.
- [15] 国立研究開発法人科学技術振興機構研究開発戦略センター. デジタルツインに関する国内外の研究開発動向. Technical report, 国立研究開発法人科学技術振興機構, 3 2022. 調査報告書 CRDS-FY2021-RR-09.
- [16] Unity Technologies. Made with unity : ロボットのデジタルツインの制作とトレーニング, 3 2021. 最終アクセス: 2024 年 12 月 19 日.
- [17] SCSK 株式会社. 工場の「デジタルツイン」で働き方を変える。トヨタ自動車が目指す魅力的な職場づくり, 2 2024. 最終アクセス: 2024 年 12 月 19 日.
- [18] Rana Azzam, Mohammad Chehadeh, Oussama Abdul Hay, Igor Boiko, and Yahya Zweiri. Learning to navigate through reinforcement across the sim2real gap. *TechRxiv Preprint*, October 2023. Preprint available on TechRxiv.
- [19] 横須賀市ハザードマップ, 10 2023. 横須賀市防災ナビより提供された最新ハザードマップ.
- [20] 沼津市津波ハザードマップ (第 4 次計画) , 2023. 沼津市の防災計画に基づく津波ハザード情報を提供.
- [21] 内閣府. 都府県別市町村別津波到達時間一覧表, 8 2012.

付録

.1 シミュレーションソース格納先

本研究で使用したシミュレーションソースコードは以下の GitHub 上のリポジトリに格納している。適宜参照されたい。

- <https://github.com/tsyu12345/Rikkyo-MasterPJ>

.2 特別研究レポート格納先

本研究経過過程である特別研究 1/2 および 3 と研究内容提案書のレポートは以下のリンクから閲覧可能である。適宜参照されたい。

- 特別研究 1 報告書
- 特別研究 2 報告書
- 研究内容提案書
- 特別研究 3 報告書
- 特別研究 3 別冊資料

.3 探索タスクマルチエージェントモデルの学習結果

.3.1 横須賀市の場合

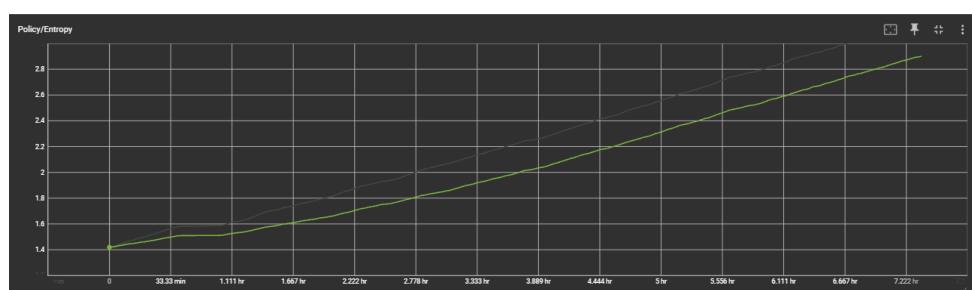


図1: エントロピーの推移

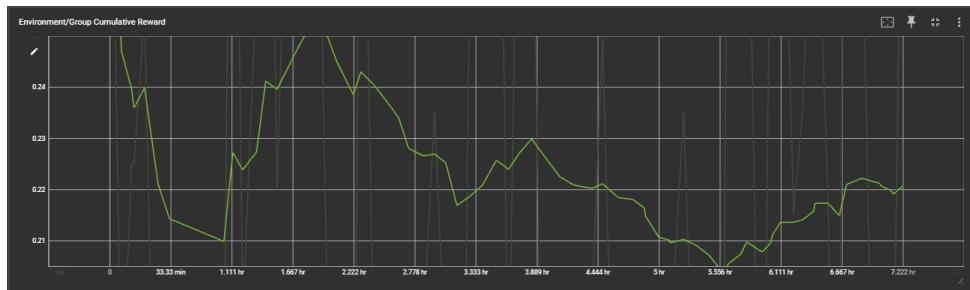


図2: グループ累積報酬の推移

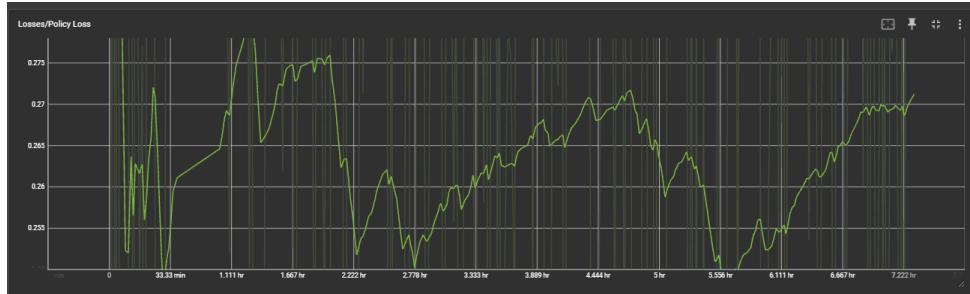


図3: ポリシー関数の平均損失

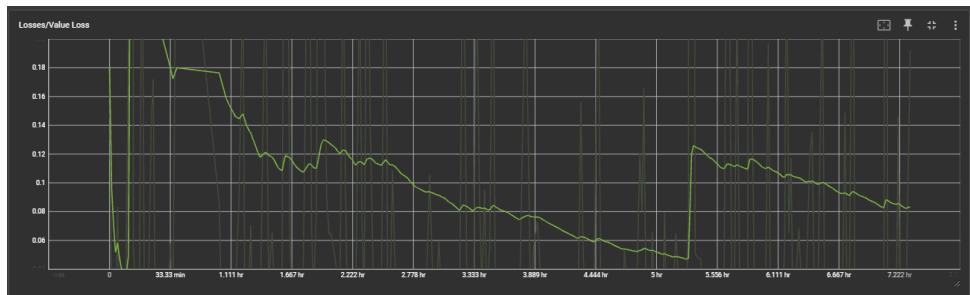


図4: 値関数の平均損失

.3.2 沼津市の場合

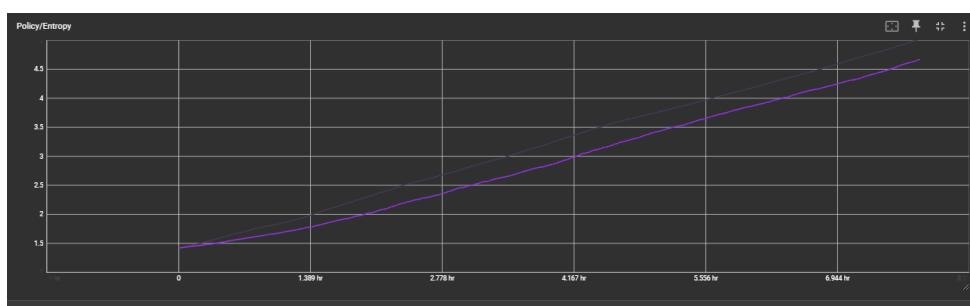


図5: エントロピーの推移

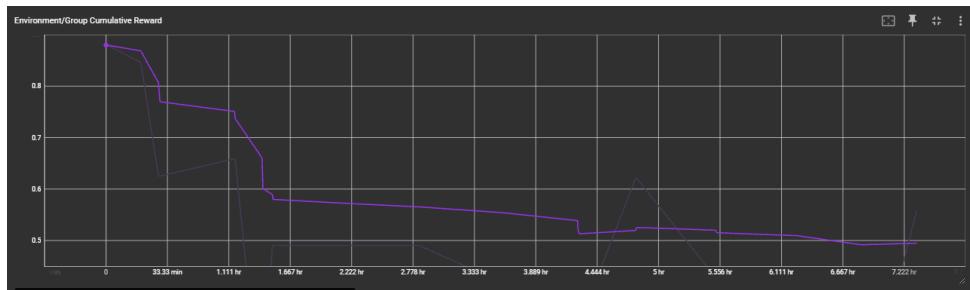


図6: グループ累積報酬の推移

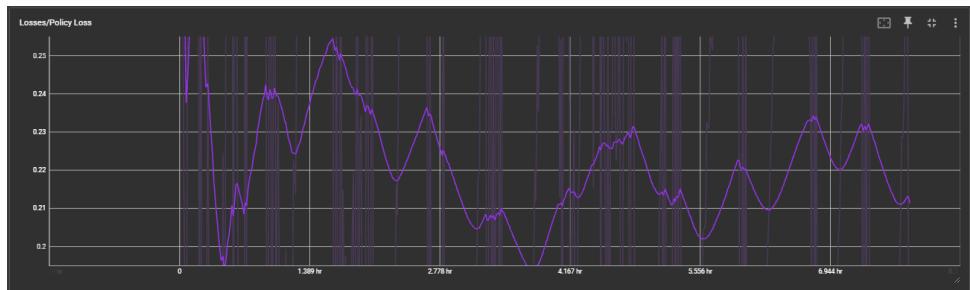


図7: ポリシー関数の平均損失

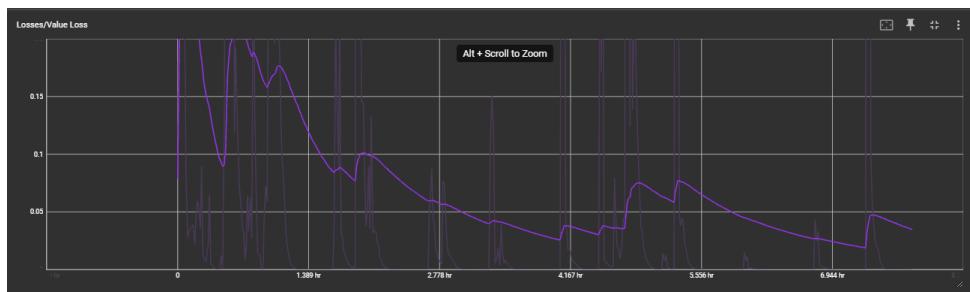


図8: 値関数の平均損失

.4 誘導タスクマルチエージェントモデルの学習結果

.4.1 横須賀市の場合

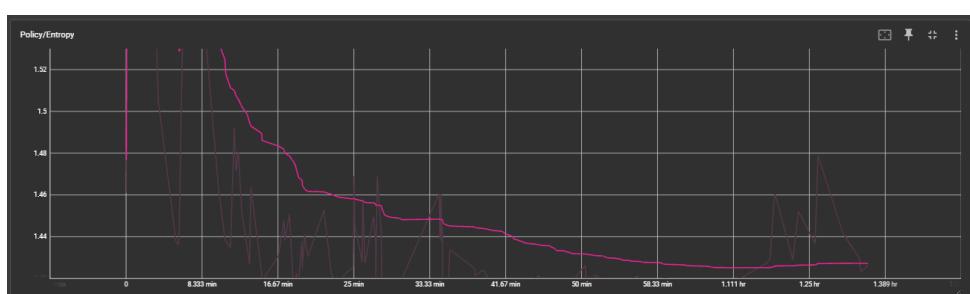


図9: エントロピーの推移

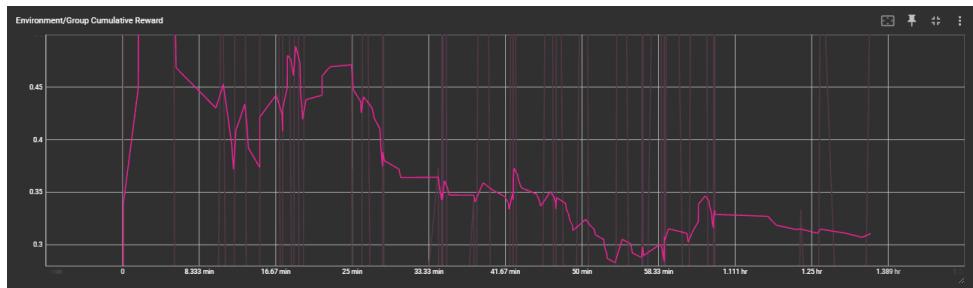


図10: グループ累積報酬の推移

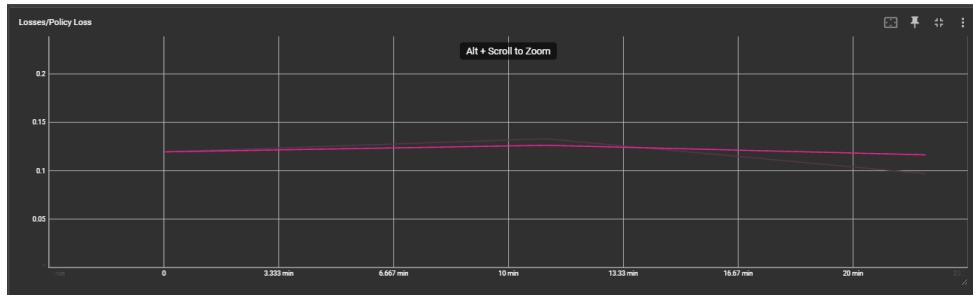


図11: ポリシー関数の平均損失

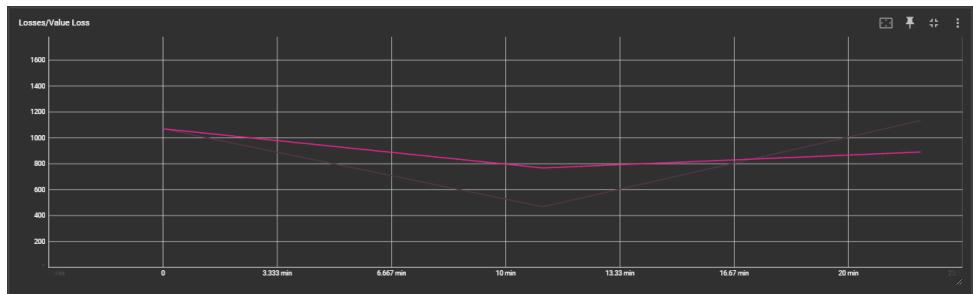


図12: 値値関数の平均損失

4.2 沼津市の場合

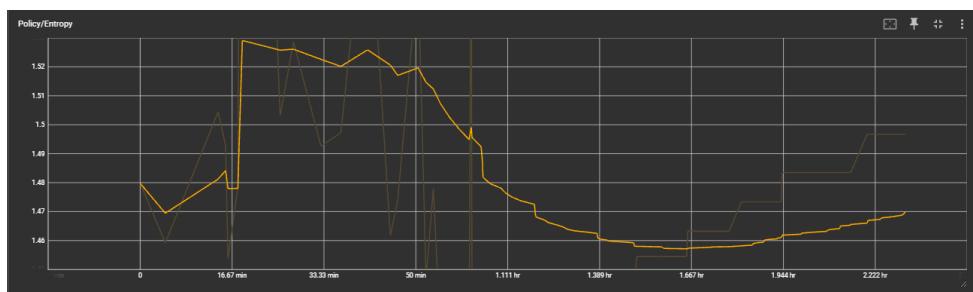


図13: エントロピーの推移

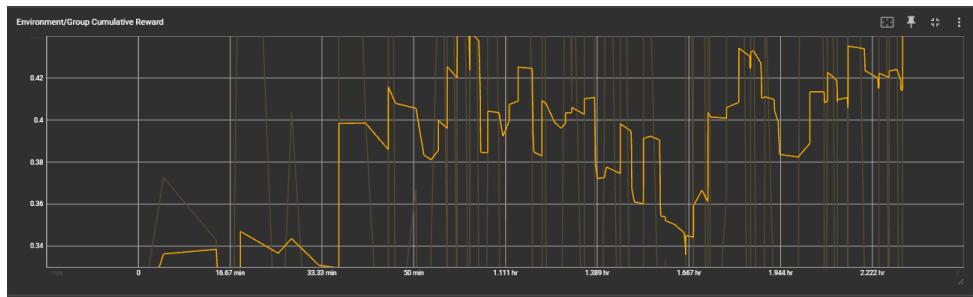


図14: グループ累積報酬の推移

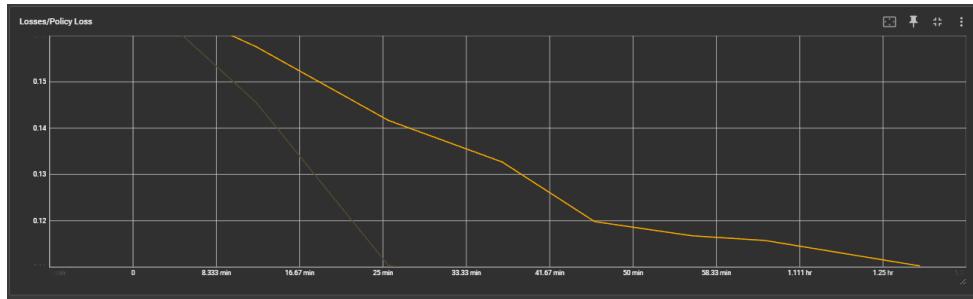


図15: ポリシー関数の平均損失

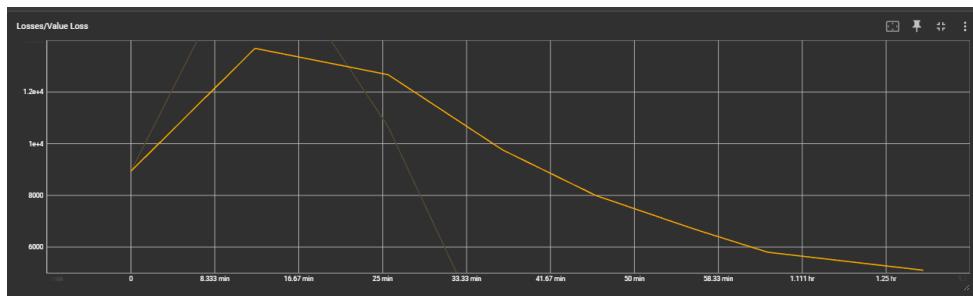


図16: 値関数の平均損失

5 探索タスクにおける発見率の推移

5.1 横須賀市の場合

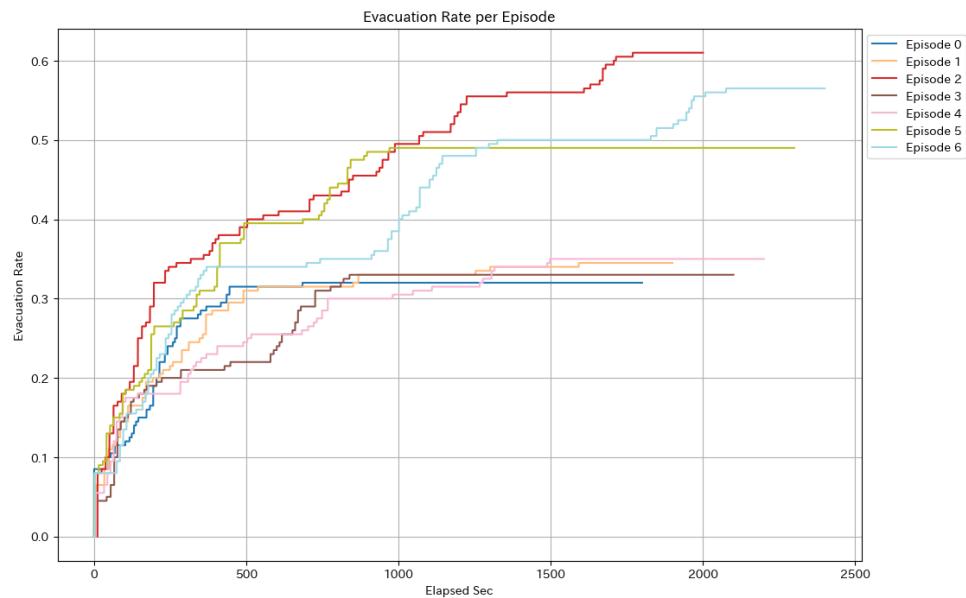


図17: ルールベースでの発見率の推移

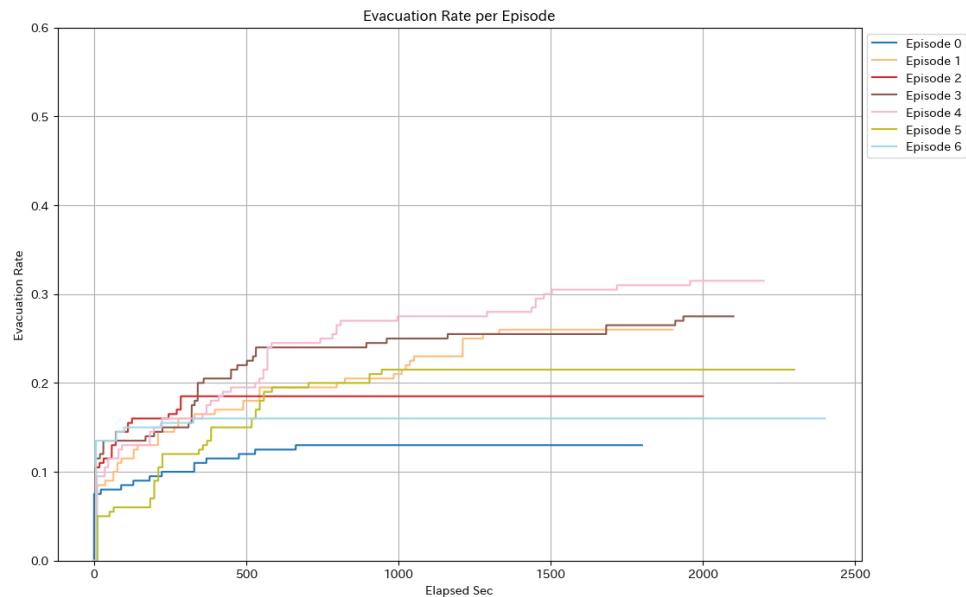


図18: マルチエージェントモデルでの発見率の推移

5.2 沼津市の場合

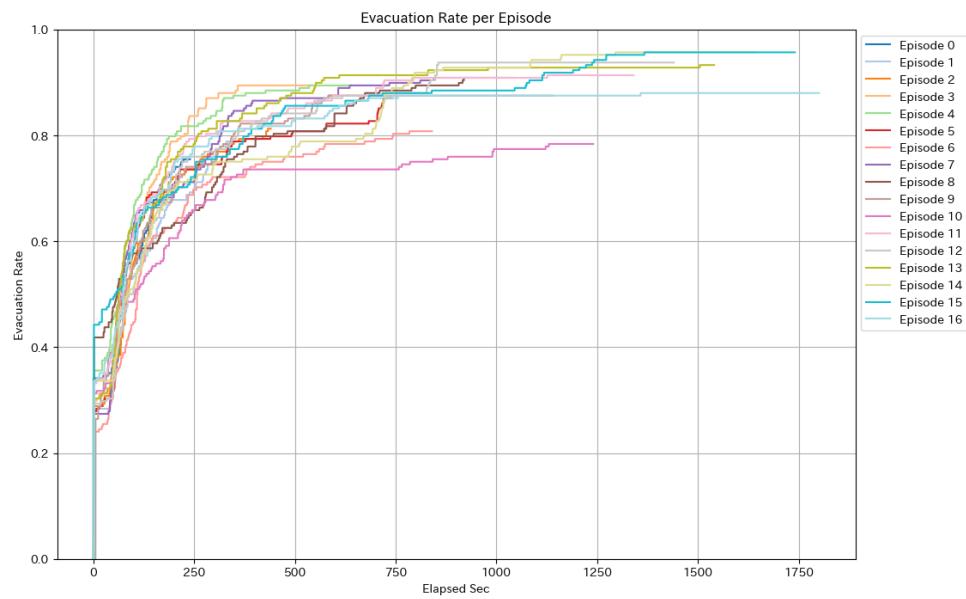


図19: ルールベースでの発見率の推移

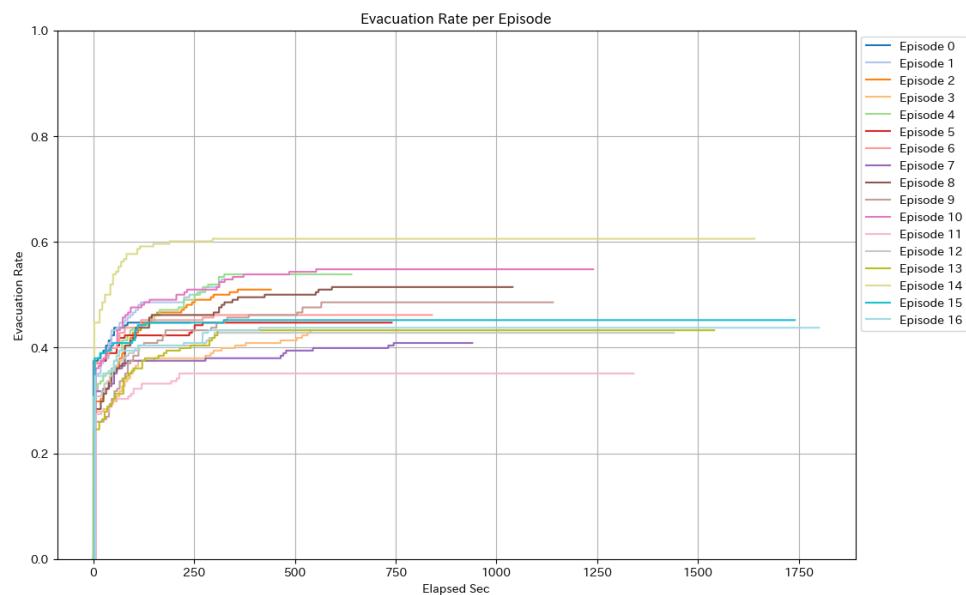


図20: マルチエージェントモデルでの発見率の推移

.6 誘導タスクにおける避難完了率の推移

.6.1 横須賀市の場合

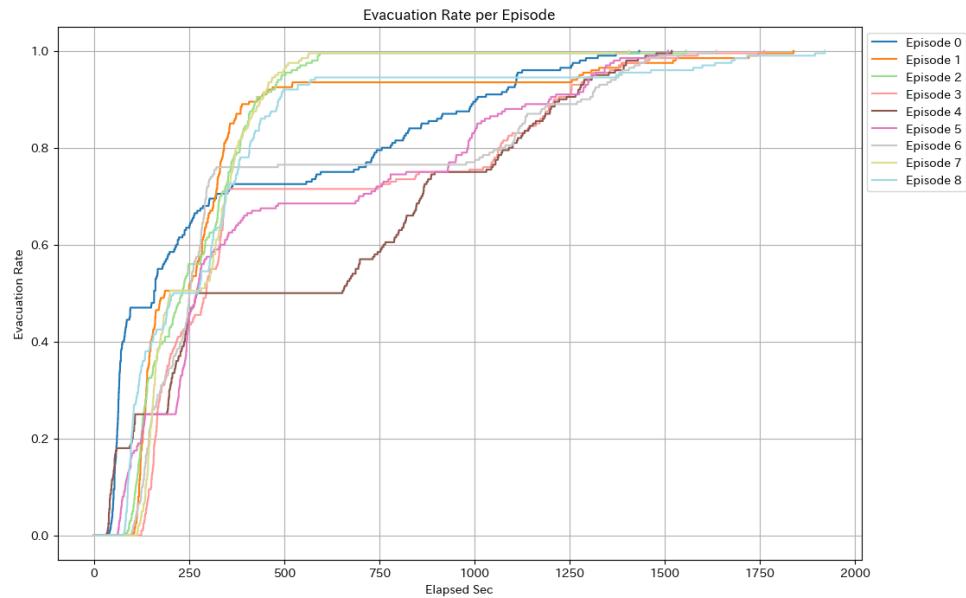


図21: 避難者のみ（誘導無）での避難完了率の推移

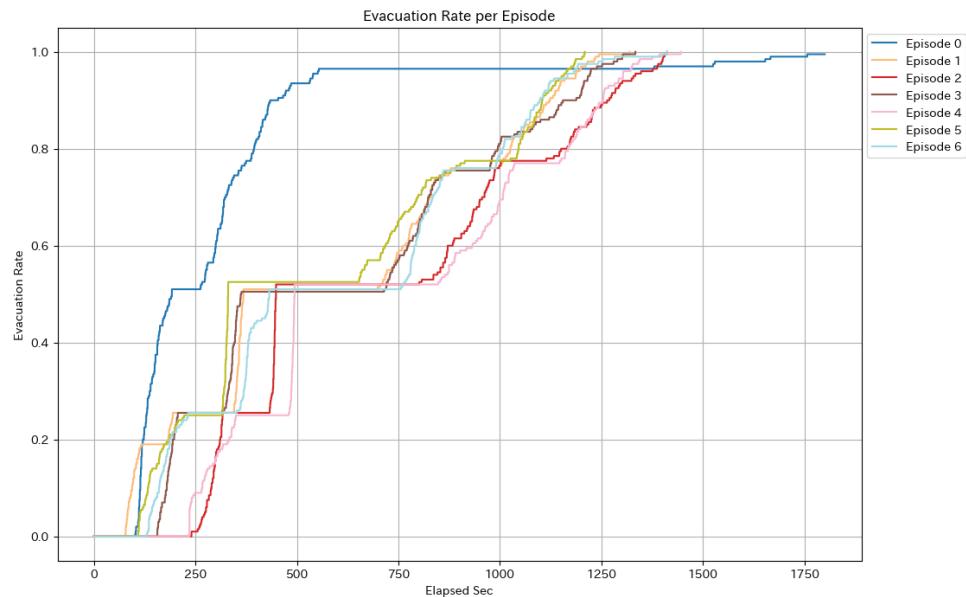


図22: ルールベースでの避難完了率の推移

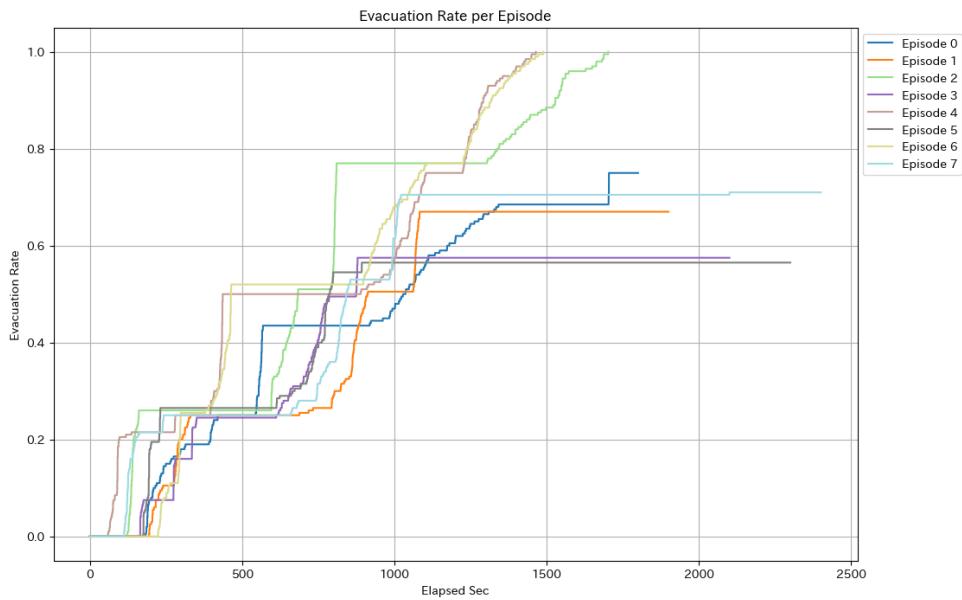


図23: マルチエージェントモデルでの避難完了率の推移

.6.2 沼津市の場合

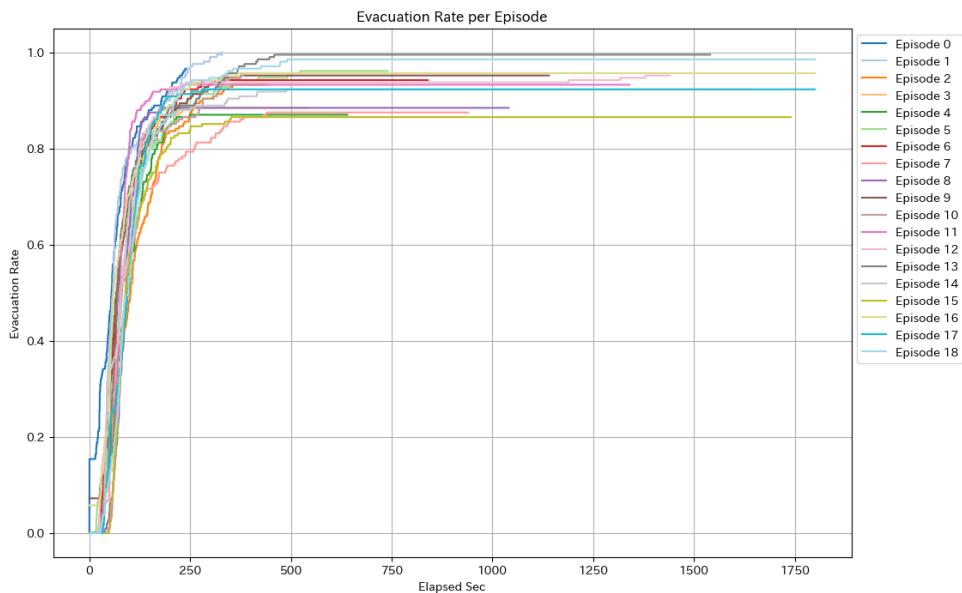


図24: 避難者のみ（誘導無）での避難完了率の推移

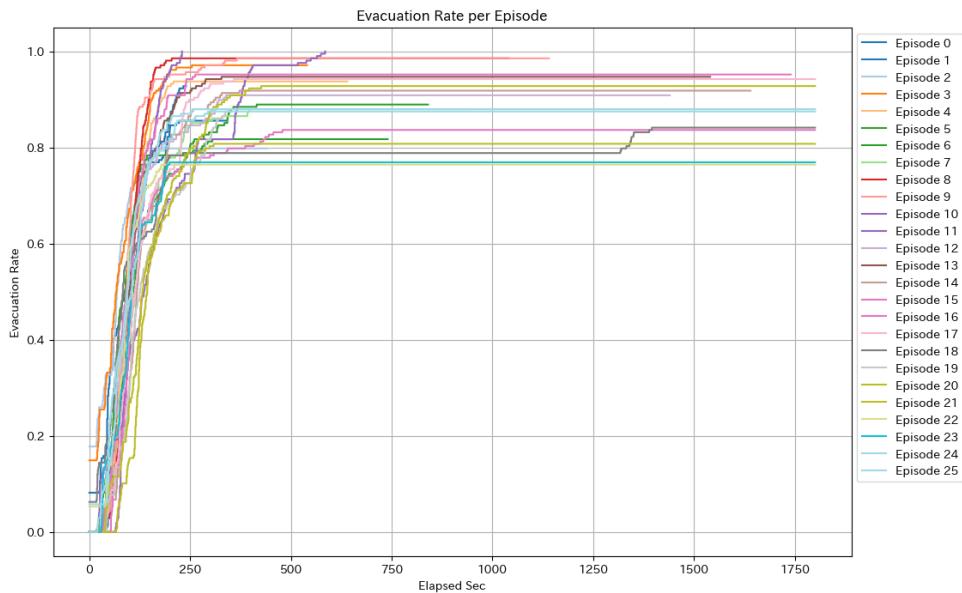


図25: ルールベースでの避難完了率の推移

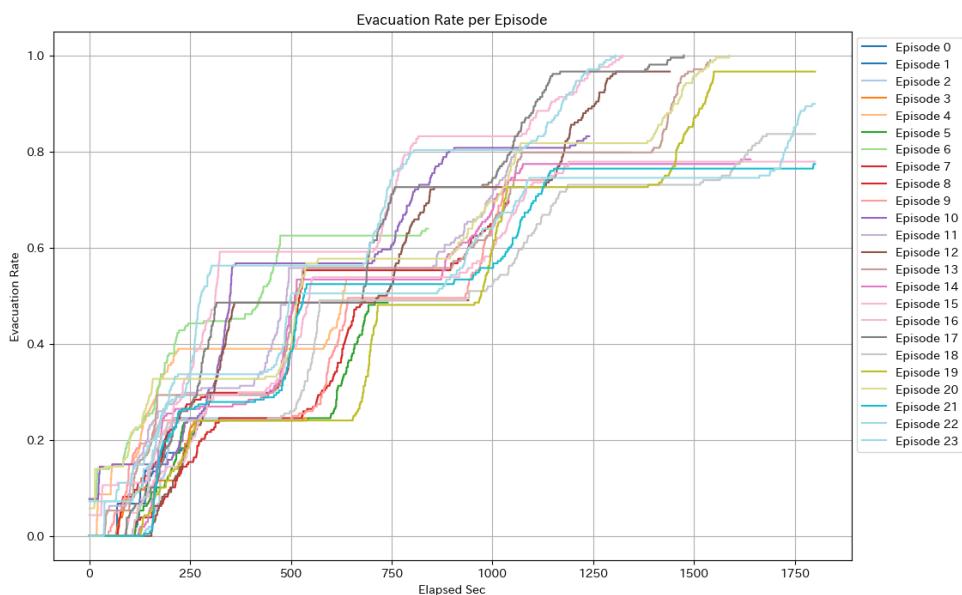


図26: マルチエージェントモデルでの避難完了率の推移